



Universitas
Harkat Negeri

**DETEKSI MAKANAN BERBASIS YOLO DENGAN ESTIMASI BERAT
NASI SEBAGAI PENDUKUNG PEMENUHAN NUTRISI**

TUGAS AKHIR

Diajukan Sebagai Salah Satu Syarat untuk Menyelesaikan Studi
Pada Program Studi DIII Teknik Komputer

Oleh:

Nama: Firman Sanjaya

NIM: 23040110

**PROGRAM STUDI D-III TEKNIK KOMPUTER
FAKULTAS SEKOLAH VOKASI
UNIVERSITAS HARKAT NEGERI**

2026

HALAMAN PERNYATAAN KEASLIAN

Yang bertandatangan di bawah ini:

Nama : Firman Sanjaya
NIM : 23040110
Jurusan / Program Studi : D3 Teknik Komputer
Jenis Karya : Tugas Akhir

Adalah mahasiswa Program Studi DIII Teknik Komputer Universitas Harkat Negeri Tegal, dengan ini saya menyatakan bahwa laporan Tugas Akhir yang berjudul **“DETEKSI MAKANAN BERBASIS YOLO DENGAN ESTIMASI BERAT NASI SEBAGAI PENDUKUNG PEMENUHAN NUTRISI”** Merupakan hasil pemikiran dan kerjasama secara orisinil dan saya susun secara mandiri dan tidak melanggar kode etika hak karya cipta. Pada laporan Tugas Akhir ini juga bukan merupakan karya yang pernah diajukan untuk memperoleh gelar akademik tertentu di suatu perguruan tinggi, dan sepanjang pengetahuan saya juga tidak terdapat karya atau pendapat yang pernah ditulis atau disebutkan di dalam daftar Pustaka.

Apabila di kemudian hari ternyata Laporan Tugas Akhir ini terbukti melanggar kode etik karya cipta atau merupakan karya yang dikategorikan dalam mengandung unsur plagiarisme, maka saya bersedia untuk melakukan penelitian baru dan menyusun laporannya sebagai Laporan Tugas Akhir, sesuai dengan ketentuan yang berlaku. Demikian pernyataan ini saya buat dengan sebenarnya dan sesungguhnya.

Tegal, 10 Mei 2026

Firman Sanjaya
23040110

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPERLUAN AKADEMIS

Sebagai civitas akademika Universitas Harkat Negeri, Saya yang bertandatangan dibawah ini:

Nama : Firman Sanjaya
NIM : 23040110
Jurusan / Program Studi : D3 Teknik Komputer
Jenis Karya : Tugas Akhir

Demi mengembangkan ilmu pengetahuan, menyetujui untuk memberikan kepada Universitas Harkat Negeri Tegal, **Hak Bebas Royalti Noneksklusif** (*None-exclusive Royalty Free Right*) atas Tugas Akhir saya yang berjudul “DETEKSI MAKANAN BERBASIS YOLO DENGAN ESTIMASI BERAT NASI SEBAGAI PENDUKUNG PEMENUHAN NUTRISI” Berserta perangkat yang ada (jika diperlukan).

Dengan Hak Bebas Royalti Noneksklusif ini Universitas Harkat Negeri Tegal berhak menyimpan, mengalih media/formatkan, mengelola dalam bentuk pangkalan data (*database*), merawat dan mempublikasikan Tugas Akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan pemilik Hak Cipta. Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Universitas Harkat Negeri Tegal

Pada tanggal : 10 Mei 2026

Yang menyatakan,

Firman Sanjaya

NIM 23040110

HALAMAN PERSETUJUAN

Tugas Akhir (TA) yang berjudul “**DETEKSI MAKANAN BERBASIS YOLO DENGAN ESTIMASI BERAT NASI SEBAGAI PENDUKUNG PEMENUHAN NUTRISI**” yang disusun oleh Firman Sanjaya, NIM 23040110 telah mendapat persetujuan pembimbing dan siap dipertahankan di depan Tim penguji Tugas Akhir (TA) Program Studi DIII Teknik Komputer Universitas Harkat Negeri Tegal.

Tegal, 10 Mei 2026

Menyetujui

Pembimbing I,

Pembimbing II,

Abdul Basit, S.Kom.,MT.
NIPY. 01.015.198

Very Kurnia Bakti, M.Kom
NIPY. 09.008.044

HALAMAN PENGESAHAN

Judul :DETEKSI MAKANAN BERBASIS YOLO
DENGAN ESTIMASI BERAT NASI SEBAGAI
PENDUKUNG PEMENUHAN NUTRISI
Nama :Firman Sanjaya
NIM :23040110
Program Studi :Teknik Komputer
Jenjang :Diploma III
Dinyatakan LULUS setelah dipertahankan di depan Tim Penguji Tugas Akhir
Program Studi DII Teknik Universitas Harkat Negeri Tegal

Tegal, 10 Mei 2026

Tim Penguji:

Pembimbing I,

Ketua Penguji,

Abdul Basit S.Kom, M.T.

NIPY. 01.015.198

Pembimbing II

Anggota Penguji I,

Very Kurniawan Bakti M.Kom

NIPY. . 09.008.044

NIPY.

Angota Penguji II

NIPY.

Mengetahui,

Ketua Program Studi DIII Teknik Komputer,
Universitas Harkat Negeri Tegal

.....

NIPY. 05.016.291

MOTTO

*“Semua manusia di muka bumi ini bingung
nanti enggak bingung kalo sudah di surga”*

-Aldi Taher-

HALAMAN PERSEMBAHAN

1. Allah SWT yang telah memberikan rahmat dan hidayahnya sehingga kami dapat menyelesaikan Tugas Akhir dan laporan ini,
2. Ibu dan Ayah tercinta, atas doa, kasih sayang, dukungan, serta pengorbanan yang tiada henti kepada penulis.
3. Dosen Pembimbing, atas bimbingan, arahan, serta ilmu yang telah diberikan selama proses penyusunan laporan ini.
4. Rekan – rekan sejawat dan teman – teman yang telah memberikan dukungan moril dan teknis sehingga laporan ini dapat terselesaikan dengan baik.

ABSTRAK

Mengatasi keterbatasan pemantauan manual pada Program Makan Bergizi Gratis (MBG), penelitian ini mengembangkan sistem deteksi makanan berbasis *computer vision* menggunakan model YOLO26 Segmentasi untuk mengidentifikasi komponen makanan dan mengestimasi berat nasi sebagai pendukung pemantauan nutrisi. *Dataset* yang digunakan terdiri dari 505 citra menu makanan dengan enam kelas objek, yaitu nasi, protein, sayur, buah, karbohidrat, dan susu yang diperoleh dari media sosial Satuan Pelayanan Pemenuhan Gizi (SPPG). Estimasi berat nasi dilakukan berdasarkan luas area hasil segmentasi (*mask*) menggunakan nilai kalibrasi 0,00011159 gram/*piksel*. Model dilatih, diuji, dan diintegrasikan ke dalam layanan REST API berbasis Flask serta aplikasi Android. Pengujian model dilakukan menggunakan tiga skenario data uji, yaitu 50, 115, dan 690 citra. Hasil pengujian menunjukkan bahwa model mampu melakukan deteksi dan segmentasi objek makanan dengan baik, dengan nilai mAP50 segmentasi sebesar 88,6%, 78,3%, dan 77,5% pada masing-masing skenario pengujian. Pada objek nasi yang menjadi fokus penelitian, model memperoleh nilai mAP50 segmentasi sebesar 96,3%, 98,3%, dan 98,6%. Selain itu, sistem berhasil melakukan estimasi berat nasi yang mendekati berat aktual serta menampilkan hasil deteksi, estimasi berat, dan perhitungan kalori melalui aplikasi Android. Hasil penelitian menunjukkan bahwa sistem yang dikembangkan mampu mendukung evaluasi menu dan pemantauan pemenuhan nutrisi pada Program MBG.

Kata kunci: *Computer Vision*, REST API, Segmentasi, YOLO, MBG.

KATA PENGANTAR

Dengan memanjatkan puji syukur kehadirat Allah SWT, Tuhan Yang Maha Pengasih dan Maha Penyayang yang telah meilmpahkan segala rahmat, hidayah dan inayah-Nya hingga terselesaikannya laporan Tugas Akhir dengan judul **“DETEKSI MAKANAN BERBASIS YOLO DENGAN ESTIMASI BERAT NASI SEBAGAI PENDUKUNG PEMENUHAN NUTRISI”**

Tugas Akhir merupakan suatu kewajiban yang harus dilaksanakan untuk memenuhi salah satu syarat kelulusan dalam mencapai derajat Ahli Madya Komputer pada program studi D-3 Teknik Komputer Universitas Harkat Negeri. Selama melaksanakan penelitian dan kemudian tersusun dalam laporan Tugas Akhir ini, banyak pihak yang telah memberikan bantuan, dukungan, dan bimbingan.

Pada Kesempatan ini, tidak lupa diucapkan terima kasih yang sebesar bersarnya kepada :

1. Bapak Sudirman said, Se, MBA selaku rektor Universitas Harkat Negeri
2. Bapak Dr.apr. Heru Nurcahyo, M.Sc Dekan Sekolah Vokasi
3. Bapak Arif Rakhman, S.E, S.Pd, M.Kom selaku Ketua Program Studi D-3 Teknik Komputer.
4. Bapak Abdul Basit S.Kom, M.T. selaku Pembimbing I.
5. Bapak Very Kurniawan Bakti M.Kom selaku Pembimbing II.
6. Kedua Orang tua saya yang selalu memberikan dukungan dan doa.
7. Teman-teman, sahabat dan saudara yang telah mendoakan, mendukung dan memberi semangat dalam menyelesaikan Tugas Akhir ini.

Semoga laporan Tugas Akhir ini dapat memberikan sumbangsih untuk pengembangan ilmu pengetahuan dan teknologi.

Tegal, 10 Mei 2026

DAFTAR ISI

JUDUL	i
HALAMAN PERNYATAAN KEASLIAN	ii
HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPERLUAN AKADEMIS.....	iii
HALAMAN PERSETUJUAN	iv
HALAMAN PENGESAHAN	v
MOTTO.....	vi
HALAMAN PERSEMBAHAN	vii
ABSTRAK	viii
KATA PENGANTAR	ix
DAFTAR ISI	x
DAFTAR GAMBAR	xii
DAFTAR TABEL	xiii
DAFTAR LAMPIRAN.....	xiv
BAB I PENDAHULUAN	1
1.1. Latar Belakang	1
1.2. Perumusan Masalah.....	7
1.3. Batasan Masalah.....	8
1.4. Tujuan Dan Manfaat.....	9
1.4.1. Tujuan	9
1.4.2. Manfaat	10
1.5. Sistematika Penulisan Laporan	11
BAB II TINJAUAN PUSTAKA	14
2.1. TEORI TERKAIT	14
2.2. LANDASAN TEORI	16
2.2.1. Pembelajaran Mendalam (<i>Deep Learning</i>)	16
2.2.2. Komputer Visi (<i>Computer Vision</i>)	17
2.2.3. Citra Digital.....	18
2.2.4. Open CV.....	19
2.2.5. Python	20
2.2.6. Flask.....	20
2.2.7. Google Collaboratory.....	21
2.2.8. Roboflow.....	22
2.2.9. Diagram Alir.....	23
2.2.10. Diagram Blok	25
BAB III METODOLOGI PENELITIAN.....	28
3.1. Prosedur Penelitian.....	28
3.1.1. Analisis Kebutuhan.....	29
3.1.2. Perancangan Sistem	29
3.1.3. Pengembangan Model.....	29
3.1.4. Pengujian Model.....	31
3.1.5. Penerapan Model	31
3.2. Metode Pengumpulan Data.....	31

3.3.1.	Pengumpulan <i>Dataset</i>	32
3.3.2.	Studi Literatur.....	32
3.3.	Waktu Dan Tempat Penelitian	33
BAB IV	ANALISA DAN PERANCANGAN SISTEM	34
4.1.	Analisa Permasalahan	34
4.2.	Analisa Kebutuhan Sistem.....	35
4.2.1.	Kebutuhan Perangkat Keras	35
4.2.2.	Kebutuhan Perangkat Lunak	36
4.2.3.	Kebutuhan Data	36
4.3.	Perancangan Sistem.....	38
4.3.1.	Perancangan Diagram Blok.....	38
4.3.2.	Perancangan <i>Flowchart</i>	39
4.4.	Desain <i>Input/Output</i>	41
4.4.1.	Desain <i>Input</i>	41
4.4.2.	Desain <i>Output</i>	42
BAB V	HASIL DAN PEMBAHASAN.....	43
5.1.	Implementasi Sistem	43
5.1.1.	Implementasi <i>Dataset</i>	43
5.1.2.	Implementasi Pelatihan Model	52
5.1.3.	Implementasi REST API.....	55
5.1.4.	Implementasi Hasil Deteksi dan Estimasi Berat	56
5.2.	Hasil Pengujian	59
5.2.1.	Pengujian Performa Model.....	60
5.2.2.	Pengujian Evaluasi Model.....	62
5.2.3.	Pengujian Estimasi Berat Nasi	72
5.2.4.	Pengujian Layanan REST API	73
5.2.5.	Pengujian Integrasi model.....	74
BAB VI	KESIMPULAN DAN SARAN	76
6.1.	Kesimpulan	76
6.2.	Saran	78
DAFTAR PUSTAKA		79
LAMPIRAN		87

DAFTAR GAMBAR

Gambar 3.1. Tahapan Metode R&D	28
Gambar 3.2. Alur kerja sistem.....	29
Gambar 3.3. Flowchat pengembangan model	30
Gambar 3.4. Lokasi Penelitian	33
Gambar 4.1. Blok Diagram	38
Gambar 4.2. Flowchart deteksi makanan	40
Gambar 4.3. Flowchart estimasi berat nasi	41
Gambar 5.1. Dataset Menu MBG	44
Gambar 5.2. Dataset Nasi untuk Estimasi Berat	45
Gambar 5.3. Perbandingan Sebelum dan Sesudah Preprocessing	47
Gambar 5.4. Perbandingan Sebelum dan Sesudah Augmentasi	50
Gambar 5.5. Histogram Sebelum dan Sesudah Augmentasi.....	51
Gambar 5.6. Hasil Respons REST API.....	56
Gambar 5.7. Hasil Deteksi dan Segmentasi Makanan	57
Gambar 5.8. Hasil Evaluasi Model.....	61
Gambar 5.9. Confusion matrix	63
Gambar 5.10. normalisasi confusion matrix	65
Gambar 5.11. Precision-Recall Curve	67
Gambar 5.12. F1-Confidence Curve.....	70
Gambar 5.13. Hasil Pengujian Integrasi Model	75

DAFTAR TABEL

Tabel 1.1. Standar gizi MBG.....	3
Tabel 2.1. Teori Terkait	14
Tabel 2.2. Simbol flowchart.....	24
Tabel 2.3. Komponen Diagram Blok.....	26
Tabel 4.1. Data Input	42
Tabel 4.2. Data Output.....	42
Tabel 5.1. Pembagian dataset Makanan.....	46
Tabel 5.2. Jumlah Anotasi Setiap Kelas	48
Tabel 5.3. Distribusi Anotasi Dataset	51
Tabel 5.4. Konfigurasi Pelatihan Model	53
Tabel 5.7. Hasil Pengujian Estimasi Berat Nasi.....	72
Tabel 5.8. Hasil Pengujian REST API.....	73

DAFTAR LAMPIRAN

Lorem

BAB I

PENDAHULUAN

1.1. Latar Belakang

Gizi adalah ilmu yang mempelajari kandungan zat pada makanan dan minuman. Gizi sangat terkait dengan kesehatan karena berperan menyediakan energi, membangun dan memelihara jaringan, serta mengatur berbagai proses tubuh [1],[2]. Gizi seimbang berarti susunan makanan dengan proporsi nutrisi (protein, karbohidrat, vitamin, mineral, dan lainnya) yang sesuai kebutuhan aktivitas, tidak berlebihan maupun kekurangan, serta tetap memperhatikan kebersihan makanan [3],[4]. Ketidakseimbangan asupan dapat memicu masalah malnutrisi maupun penyakit tidak menular, misalnya *stunting* (sebagai indikator utama malnutrisi) [5], obesitas akibat penumpukan lemak karena ketidakseimbangan energi jangka panjang [6], serta diabetes yang ditandai peningkatan gula darah dan berisiko menimbulkan komplikasi serius seperti penyakit jantung, stroke, dan gangguan organ [7]. Di Indonesia, masalah gizi masih menjadi hambatan besar karena pola makan cenderung meningkat pada lemak, gula, dan garam tetapi rendah protein hewani dan serat [8]. Rendahnya kesadaran dan pengetahuan tentang menu sehat serta variasi makanan juga memperparah persoalan, karena kurangnya wawasan gizi membuat banyak orang belum memahami komposisi makan yang seimbang [9],[10].

Survei SEANUTS II (2019–2020) menunjukkan 20,6% anak di perkotaan dan 33,4% anak di perdesaan di Jawa dan Sumatera mengalami

stunting, sementara 9–12% anak menderita obesitas [11]. Temuan ini menegaskan adanya kesenjangan kondisi gizi yang nyata antara wilayah kota dan desa [12]. Selain itu, analisis mendalam tentang masalah gizi di Indonesia menunjukkan bahwa 24,9% keluarga mengalami tiga masalah gizi sekaligus, yaitu kekurangan gizi, kelebihan gizi, dan kekurangan zat gizi mikro [13]. Ketiga masalah ini berdampak buruk pada kualitas sumber daya manusia dan meningkatkan risiko penyakit tidak menular [14],[15]. Pola makan yang cenderung mengandalkan makanan cepat saji tinggi lemak dan kalori turut mendorong kenaikan obesitas [16]. Di sisi lain, masalah kurang gizi belum teratasi, yang akhirnya memperburuk masalah gizi ganda di Indonesia [17]. Penelitian lain juga menemukan bahwa kurangnya pengetahuan tentang nutrisi di keluarga sangat berkaitan dengan tingginya angka *stunting* dan anemia pada anak-anak Indonesia [18]. Hal ini menunjukkan bahwa perlu adanya upaya yang terencana untuk meningkatkan pengetahuan tentang gizi kepada masyarakat.

Namun, akses informasi gizi di masyarakat masih terbatas sehingga dibutuhkan solusi berbasis teknologi agar edukasi gizi lebih mudah diakses dan menjangkau lebih banyak orang. Sosialisasi gizi masih didominasi metode konvensional yang kurang efektif menarik perhatian, sehingga upaya pemerintah melalui program Gerakan Masyarakat Hidup Sehat (GERMAS) masih menemui kendala dalam mendorong partisipasi aktif karena materi dan cara penyampaiannya belum cukup memikat [19],[20],[21]. Menindak lanjuti kendala sosialisasi tersebut, pemerintah menyusun program Makan Bergizi

Gratis (MBG) yang berperan sebagai intervensi gizi dan penguatan pendidikan inklusif-berkelanjutan [22],[23]. Pelaksanaan program ini dikoordinasikan oleh Badan Gizi Nasional guna memastikan pemenuhan gizi seimbang [24]. Standar gizi MBG menurut kelompok sasaran dirangkum pada Tabel 1.1.

Tabel 1.1. Standar gizi MBG

No	Sasaran	Energi (kkal)	Energi (%)	Protein	Lemak	Karbohidrat
1	Siswa TK/PAUD	328,0	23,4	25,0	23,7	20,9
2	Siswa SD (1–3)	368,8	22,3	23,1	24,1	20,1
3	Siswa SD (kelas 4– 6)	531,0	32,2	33,1	30,9	31,0
4	Siswa SMP	719,0	32,3	34,8	30,7	30,8
5	Siswa SMA	762,5	32,1	36,4	31,0	30,4

Dengan acuan ini, porsi pemberian makan disesuaikan jenjang agar lebih tepat sasaran. Sejumlah kajian *school-feeding* juga menunjukkan dampak yang cenderung positif pada *antropometri* dan kehadiran sekolah, meski pengaruhnya pada prestasi akademik dan status gizi jangka panjang masih belum konklusif [25],[26]. Karena itu, MBG diharapkan dapat memperkuat mutu gizi anak sekaligus mendukung proses belajar dan capaian akademik dalam jangka panjang [27]. Evaluasi penakaran gizi pada skala

operasional besar yang masih dilakukan secara manual umumnya memiliki tingkat akurasi yang rendah serta rawan terjadi tidak *konsistenan* dalam penilaian dan kesalahan manusia [28]. Untuk mendukung pelaksanaan MBG agar lebih mudah dipantau dan tepat sasaran, diperlukan metode yang cepat dan objektif dalam mengenali jenis menu serta porsi makanan di lapangan. Oleh karena itu, penelitian ini memanfaatkan pendekatan *computer vision* untuk mengidentifikasi komponen makanan secara otomatis sebagai dasar evaluasi program.

Perkembangan teknologi kecerdasan buatan, khususnya *computer vision*, memberikan peluang besar untuk menghadirkan solusi praktis dalam membantu masyarakat memahami kandungan gizi makanan melalui analisis citra digital [29]. Teknologi ini memungkinkan identifikasi objek makanan secara otomatis hanya dari gambar yang diambil menggunakan kamera ponsel, sehingga estimasi nilai nutrisi dapat dilakukan dengan lebih cepat [30]. Sejumlah penelitian juga menegaskan bahwa pendekatan berbasis foto dapat mengurangi beban pencatatan manual dan mendukung penilaian asupan makan yang lebih efisien, umumnya melalui tahapan segmentasi, pengenalan jenis makanan, dan estimasi porsi/kalori/nutrisi [31],[32]. Meski demikian, akurasi sistem sangat dipengaruhi oleh kondisi di lapangan misalnya pencahayaan, latar belakang, keberadaan makanan campuran, serta variasi penyajian sehingga diperlukan data latih yang relevan [33]. Selain data latih yang relevan, penerapan standarisasi cara memotret juga diperlukan agar perbedaan kondisi pemotretan tidak terlalu memengaruhi hasil estimasi [34].

Untuk mengatasi variasi kondisi lapangan tersebut, diperlukan metode pendeteksian/segmentasi objek makanan yang andal agar tahap pengenalan dan estimasi dapat berjalan lebih akurat. Model deteksi objek modern seperti YOLO (You Only Look Once) telah digunakan secara luas karena mampu melakukan deteksi dengan akurasi tinggi [35]. Sejumlah penelitian menunjukkan bahwa penggunaan YOLO dalam sistem pengenalan makanan dapat meningkatkan ketepatan estimasi kalori dan komposisi nutrisi, karena jenis makanan dapat terdeteksi secara cepat sebelum dilakukan perhitungan nilai gizinya [36]. Selain pendekatan deteksi berbasis *bounding box*, pengembangan YOLO juga telah diarahkan pada tugas segmentasi, di mana model tidak hanya memprediksi lokasi dan kelas objek, tetapi juga menghasilkan *mask* pada tingkat *piksel* untuk setiap objek [37]. Segmentasi tingkat *piksel* memungkinkan ekstraksi area objek secara langsung pada makanan, sehingga batas objek direpresentasikan mengikuti kontur aktualnya [38]. Metode berbasis *mask* ini memberikan informasi yang lebih rinci dan memungkinkan perhitungan luas area sebagai dasar analisis porsi [39]. Pada proses estimasi volume makanan, luas area hasil segmentasi dimanfaatkan sebagai informasi untuk memperkirakan volume dan kandungan gizi [40].

Akses deteksi objek dapat dibuat sebagai layanan REST API yang menjalankan YOLO pada sisi server, sehingga klien hanya mengirim citra dan menerima keluaran deteksi melalui HTTP tanpa integrasi model di perangkat klien [41]. Pada implementasi layanan seperti ini, citra umumnya diunggah melalui *RESTful* web API dengan metode HTTP POST dan server

mengembalikan respons JSON berisi prediksi agar mudah diolah oleh aplikasi klien [42]. Untuk menekan latensi dan beban jaringan, klien dapat melakukan *praproses* ringan seperti *resize*/kompresi sebelum pengiriman, pendekatan serupa juga digunakan pada sistem *edge-assisted* di mana citra dikompresi lalu dikirim ke server untuk diproses, dan hasilnya dikirim kembali ke perangkat klien [43].

Sejalan dengan itu, tinjauan sistematis melaporkan bahwa *image-based food-recognition systems* (IBFRS) yang memanfaatkan kamera perangkat seluler dan teknik *computer vision* dapat menyederhanakan pencatatan konsumsi serta meningkatkan objektivitas pemantauan dibanding metode *recall* atau pencatatan manual [44]. Dengan demikian, penelitian ini diharapkan dapat mendukung pemantauan menu dan porsi MBG secara lebih cepat, objektif, dan mudah diintegrasikan ke layanan digital.

Berdasarkan kebutuhan pemantauan pelaksanaan program Makan Bergizi Gratis (MBG) yang cepat dan objektif, penelitian ini akan mengembangkan solusi berbasis *computer vision* untuk mengenali komponen menu serta memperkirakan porsi nasi dari citra. Riset ini berfokus pada pelatihan model YOLO untuk deteksi dan segmentasi makanan, pemanfaatan keluaran *mask* atau luas area sebagai dasar estimasi porsi yang kemudian dikaitkan dengan acuan standar gizi MBG, serta integrasi model ke layanan REST API agar pengguna cukup mengunggah foto dan menerima hasil identifikasi menu beserta ringkasan estimasi porsi secara otomatis. Evaluasi dilakukan pada akurasi, ketahanan terhadap variasi kondisi pemotretan, dan

kecepatan respons layanan, sehingga diharapkan menghasilkan prototipe sistem pemantauan menu dan estimasi porsi nasi pada MBG yang praktis.

1.2. Perumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, pemantauan menu dan porsi makanan pada Program Makan Bergizi Gratis (MBG) masih memerlukan metode yang lebih cepat, objektif, dan mudah diintegrasikan dengan sistem digital. Oleh karena itu, penelitian ini memanfaatkan teknologi *computer vision* berbasis YOLO untuk mendeteksi makanan dan mengestimasi berat nasi dari citra digital. Adapun perumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana merancang sistem berbasis *computer vision* untuk mendeteksi dan menyegmentasi komponen makanan pada menu Makan Bergizi Gratis (MBG) secara otomatis dari citra digital?
2. Sejauh mana kinerja model YOLO dalam mendeteksi dan menyegmentasi objek makanan pada menu MBG berdasarkan metrik evaluasi yang digunakan?
3. Bagaimana mengimplementasikan model deteksi dan segmentasi makanan ke dalam layanan REST API agar dapat diintegrasikan dengan aplikasi klien?
4. Bagaimana memanfaatkan hasil segmentasi objek nasi berupa *mask* dan luas area sebagai dasar estimasi berat nasi?

5. Bagaimana kinerja sistem yang dikembangkan ditinjau dari akurasi deteksi dan segmentasi, akurasi estimasi berat nasi, serta performa layanan REST API?

1.3. Batasan Masalah

Agar penelitian ini tidak meluas dari maksud dan tujuannya, maka permasalahan dibatasi sebagai berikut:

1. Pengenalan jenis makanan hanya dilakukan pada jenis makanan yang tersedia dalam *dataset* yang digunakan dan tidak mencakup seluruh jenis makanan secara umum.
2. Variasi kondisi pencahayaan, latar belakang gambar, serta kualitas kamera tidak dikaji secara mendalam dan bergantung pada karakteristik *dataset* yang digunakan.
3. Penelitian ini berfokus pada proses deteksi dan pengenalan jenis makanan serta estimasi berat nasi berdasarkan citra digital, sedangkan perhitungan kebutuhan nutrisi secara rinci tidak termasuk dalam ruang lingkup penelitian.
4. Citra makanan yang digunakan merupakan citra digital dari *dataset* tertentu dan tidak mencakup kondisi ekstrem seperti pencahayaan rendah, sudut pengambilan yang terlalu miring, atau objek makanan yang tertutup sebagian.
5. Penelitian ini berfokus pada pembangunan dan pelatihan model YOLO, sedangkan pengembangan aplikasi hanya sebatas integrasi model ke

dalam aplikasi tanpa membahas pengembangan aplikasi secara menyeluruh.

6. Perbandingan performa dengan metode atau model lain dilakukan secara terbatas dan tidak menjadi fokus utama penelitian.

1.4. Tujuan Dan Manfaat

Berdasarkan rumusan masalah yang telah diuraikan sebelumnya, penelitian ini dilakukan sebagai upaya untuk memperoleh hasil yang sesuai dengan fokus penelitian serta memberikan manfaat dan tujuan.

1.4.1. Tujuan

Mengacu pada rumusan masalah yang telah dipaparkan, tujuan dari penelitian ini adalah:

1. Merancang sistem berbasis *computer vision* untuk mengidentifikasi komponen makanan pada menu Makan Bergizi Gratis (MBG) secara otomatis dari citra.
2. Mengevaluasi kemampuan model YOLO dalam mendeteksi/menyegmentasi objek makanan pada kondisi lapangan yang bervariasi.
3. Mengimplementasikan model deteksi/segmentasi makanan dalam bentuk layanan REST API agar mudah diintegrasikan dengan aplikasi klien.

4. Menganalisis pengaruh *praproses* citra (*resize/kompresi*) terhadap akurasi deteksi serta waktu respons sistem.
5. Memanfaatkan hasil segmentasi (*mask/luas area*) sebagai dasar pendukung evaluasi porsi/komponen menu untuk kebutuhan pemantauan MBG.
6. Mengukur kinerja sistem dari sisi akurasi deteksi/segmentasi dan performa layanan untuk memastikan sistem layak digunakan.

1.4.2. Manfaat

Penelitian ini diharapkan memberikan manfaat bagi mahasiswa, Universitas Harkat Negeri, serta masyarakat, baik dari aspek akademik maupun penerapan teknologi di bidang gizi dan kesehatan.

1. Bagi Mahasiswa

- a. Mendorong kreativitas mahasiswa dalam mengembangkan solusi teknologi untuk permasalahan nyata di masyarakat.
- b. Membantu mahasiswa meningkatkan kemampuan menyusun laporan ilmiah dan dokumentasi penelitian.

2. Bagi Universitas Harkat Negeri

- a. Menjadi kontribusi nyata dalam pengembangan ilmu pengetahuan dan teknologi (IPTEK) di bidang kesehatan, gizi, dan kecerdasan buatan.

- b. Menambah koleksi pustaka ilmiah kampus mengenai penelitian yang memadukan teknologi AI dengan pemecahan masalah kesehatan masyarakat.

3. Bagi Masyarakat

- a. Membantu masyarakat memperoleh informasi mengenai jenis makanan melalui citra digital secara lebih mudah.
- b. Meningkatkan kesadaran masyarakat terhadap pentingnya memahami kandungan gizi dalam makanan sehari-hari.
- c. Mempermudah masyarakat dalam memantau pola makan secara mandiri melalui teknologi yang dapat digunakan pada perangkat sehari-hari.
- d. Memperkenalkan penerapan teknologi *computer vision* dalam kehidupan sehari-hari sebagai solusi inovatif untuk meningkatkan *literasi* gizi dan kesehatan.

1.5. Sistematika Penulisan Laporan

Laporan Tugas Akhir ini terdiri dari enam bab yaitu, yang masing-masing bab dengan perincian sebagai berikut ini.

1. BAB I : PENDAHULUAN

Pada bab ini dibahas permasalahan penelitian secara keseluruhan yang meliputi latar belakang penelitian, perumusan masalah, batasan masalah, tujuan dan manfaat penelitian, serta sistematika penulisan laporan. Selain itu,

pada bab ini dijelaskan mengenai pentingnya pemantauan gizi dalam program Makan Bergizi Gratis (MBG) serta pemanfaatan teknologi *computer vision* dan metode YOLO untuk mendeteksi makanan dan mendukung estimasi porsi nasi secara otomatis.

2. BAB II : TINJAUAN PUSTAKA

Pada bab ini dibahas kajian pustaka yang mencakup penelitian terdahulu yang relevan serta teori-teori yang menjadi landasan dalam penelitian. Penelitian terdahulu digunakan sebagai bahan perbandingan dan referensi dalam pengembangan sistem. Sementara itu, landasan teori membahas konsep-konsep yang berkaitan dengan *computer vision*, *deep learning*, YOLO, segmentasi citra, REST API, serta teknologi pendukung lainnya yang digunakan dalam penelitian.

3. BAB III : METODOLOGI PENELITIAN

Pada bab ini dibahas tahapan dan metode penelitian yang digunakan dalam pengembangan sistem secara sistematis dan terarah. Pembahasan meliputi metode penelitian, pengumpulan *dataset*, *preprocessing* citra, proses pelatihan model YOLO, pengujian model, hingga penerapan sistem. Selain itu, dijelaskan pula teknik pengumpulan data dan metode evaluasi yang digunakan untuk mengukur performa sistem.

4. BAB IV : ANALISA DAN PERANCANGAN SISTEM

Pada bab ini dibahas analisis kebutuhan sistem serta perancangan sistem deteksi makanan berbasis YOLO. Pembahasan meliputi alur kerja sistem, perancangan proses deteksi dan segmentasi makanan, estimasi porsi nasi berdasarkan hasil segmentasi, serta integrasi model ke dalam layanan REST API agar dapat digunakan oleh aplikasi klien.

5. BAB V : HASIL DAN PEMBAHASAN

Pada bab ini dibahas hasil implementasi sistem serta proses pengujian model yang telah dikembangkan. Pengujian dilakukan untuk mengetahui kemampuan model dalam mendeteksi dan menyegmentasi makanan. Selain itu, hasil pengujian digunakan sebagai bahan evaluasi terhadap performa, akurasi, dan keandalan sistem yang dibangun.

6. BAB VI : KESIMPULAN DAN SARAN

Pada bab ini berisi kesimpulan dari hasil penelitian yang telah dilakukan mengenai “Deteksi Makanan Berbasis YOLO Dengan Estimasi Berat Nasi Sebagai Pendukung Pemenuhan Nutrisi” yang disusun berdasarkan hasil analisis dan pembahasan pada bab-bab sebelumnya. Selain itu, bab ini juga memuat saran-saran yang diharapkan dapat menjadi bahan pertimbangan dan referensi untuk pengembangan penelitian selanjutnya.

BAB II

TINJAUAN PUSTAKA

2.1. TEORI TERKAIT

Dalam pengembangan penelitian ini, beberapa penelitian terdahulu yang relevan digunakan sebagai acuan dalam perancangan penelitian. Kajian tersebut dirangkum pada Tabel 2.1.

Tabel 2.1. Teori Terkait

No.	Rujukan (Penulis/Tahun)	Data, <i>Dataset</i> , Masukan	Model, Algoritma	Capaian / Hasil Evaluasi	<i>Research</i> Gap
1	Agarwal, Choudhury, Ahuja, Sarkar (Journal of Food Processing and Preservation, 2023) [45] Hybrid Deep Learning Algorithm-Based Food Recognition and Calorie Estimation.	Dataset: Indian FoodNet-30 (± 5.500 Citra, 30 kelas makanan). Citra di-resize menjadi 640×640 ; split 80% untuk training dan 10% untuk testing 10%.	Arsitektur hybrid: Mask R-CNN untuk segmentasi; fitur dari hasil segmentasi diklasifikasi menggunakan YOLOv5. Parameter simulasi: batch size 2; learning rate 0,001; optimizer Adam; epochs 25; device CPU.	Akurasi sistem yang dilaporkan 97,12%. • Performa (Mask R-CNN+YOLOv5): accuracy 0,97125; precision 0,96415; F-score 0,96584; sensitivity 0,96754; specificity 0,96452.	Estimasi volume bergantung pada objek referensi dan asumsi bentuk “bowl-like”. Keterbatasan yang diakui variasi tipe/bentuk/ukuran/persentase makanan masih menantang.
2	Ferreira, Cerqueira, Ribeiro	Dataset: 175 citra dasar piring kantin, 860 citra setelah	YOLOv11 untuk deteksi/segmentasi pada	mAP = 0.343; precision = 0.62;	Fokus utama bukan estimasi porsi.

	(Applied Sciences, 2025) [46] Food Waste Detection in Canteen Plates Using YOLOv11.	augmentasi (zoom/crop/rotate/flip). Labeling memakai Roboflow.	piring kantin.	recall = 0.322.	Tidak menguji dampak preprocessing terhadap akurasi & waktu respons.
3	Chrintz-Gath, Daivadanam, Matta, McKeever (JMIR Formative Research, 2025) [47] Image-Based Dietary Assessment Using the Swedish Plate Model: Evaluation of Deep Learning–Based You Only Look Once (YOLO) Models.	Dataset: 3707 citra berlabel, 42 kelas makanan. Sumber data: Roboflow Universe dan Kaggle. Split: 3570 train, 131 validation, 6 test. Preprocessing: Auto-Orient, Resizing, Auto-Adjust Contrast; augmentasi: Rotation ($\pm 15^\circ$), Grayscale (10%), Noise.	Perbandingan model: YOLOv7 vs YOLOv8 vs YOLOv9. Metrik evaluasi: precision, recall, mAP@0.5, mAP@0.5 :0.95, F1-score.	Hasil terbaik YOLOv8 : precision 0.82382; recall 0.67553. mAP@0.5 = 0.70447; mAP@0.5:0.95 = 0.53606; F1-score 0.63.	Test set sangat kecil = 6 citra Fokus pada identifikasi, belum ke estimasi berat.
4	Gonzalez, Garcia, Velastin, GholamHossaini, Tejeda, Farias (Sensors, 2024) [48] Automated Food Weight and Content	Dataset segmentasi: 1025 citra, 14 kelas Estimasi berat nasi: 48 citra porsi nasi, tiap porsi ditimbang.	YOLOv8L-Seg untuk segmentasi piksel pada objek makanan.	Segmentasi: mAP@0.5 = 0.895. Deteksi: mAP@0.5 = 0.873.	Pendekatan porsi/berat bergantung pada depth camera. Belum ada analisis dampak

	Estimation Using Computer Vision and AI Algorithms.				resize/kompresi citra terhadap akurasi dan waktu respons.
5	S., Rajesh Kumar; Prem Kumar, Josephine (Engineering, Technology & Applied Science Research, 2025) [49] Food Object Detection Using Custom-Trained YOLOv8 with Roboflow Integration.	Dataset: 1,800 gambar high-resolution untuk 6 kelas makanan. Pembagian data: train 70% (1,260), validation 15% (270), test 15% (270).	Model: YOLOv8 + Roboflow pipeline. Konfigurasi training: input 416×416; batch size 64, learning rate 0.001, momentum 0.9, max batches 6000, classes = 6.	Validasi: mAP@0.5 dilaporkan > 92% (rentang mAP@0.5 per kelas ~92.2%–97.8%). Kecepatan inferensi: >25 FPS pada GPU NVIDIA T4.	Fokus hanya deteksi bbox. Belum membahas estimasi porsi/berat /kalori

2.2. LANDASAN TEORI

Berdasarkan kebutuhan dan ruang lingkup penelitian, landasan teori pada penelitian ini meliputi konsep-konsep dasar yang berkaitan dengan metode dan teknologi yang digunakan, yaitu:

2.2.1. Pembelajaran Mendalam (*Deep Learning*)

Pembelajaran mendalam (*Deep Learning*) adalah bagian dari *machine learning* yang memanfaatkan jaringan saraf tiruan berlapis-lapis (*deep neural networks*) untuk mempelajari representasi data

secara otomatis [50]. Menurut LeCun, Bengio, dan Hinton, *deep learning* mempunyai kemampuan untuk mengekstraksi fitur kompleks dari data visual, audio, dan teks tanpa membutuhkan ekstraksi fitur manual [51]. Teknologi *deep learning* berkembang pesat seiring meningkatnya kemampuan komputasi GPU dan optimalisasi arsitektur model [52].

2.2.2. Komputer Visi (*Computer Vision*)

Komputer Visi (*Computer Vision*) adalah cabang ilmu komputer yang mempelajari cara agar mesin dapat “melihat” dan menafsirkan informasi visual dari citra atau video menjadi representasi yang bermakna untuk pengambilan keputusan [53]. *Computer vision* merupakan ilmu komputer yang bekerja dengan cara meniru kemampuan visual manusia, yaitu mengembangkan sistem yang sangat mirip dengan fungsi umum sistem visual manusia [54],[55]. Pengolahan citra adalah metode untuk mengatasi kesulitan dalam pemrosesan gambar, sementara *computer vision* bertugas membuat penilaian terhadap objek fisik berdasarkan informasi visual yang diterima [56]. Bidang ini menggabungkan teknik pengolahan citra digital (PCD), pembelajaran mesin, dan kecerdasan buatan (AI) untuk memungkinkan komputer memahami dan mengenali objek visual, seperti pada tugas klasifikasi gambar, deteksi, segmentasi objek, dan pelacakan. Perkembangan *computer vision* didukung oleh arsitektur

jaringan saraf seperti CNN dan model *multimodal* berskala besar, namun tantangan terkait efisiensi komputasi, *interpretabilitas*, dan generalisasi masih menjadi fokus penelitian [57].

2.2.3. Citra Digital

Citra digital merupakan hasil pengolahan citra yang diproses menggunakan komputer dan disajikan dalam bentuk numerik melalui proses digitalisasi data citra analog ke digital, sehingga memungkinkan pemanfaatannya dalam berbagai bidang dan proses pengolahan lanjutan [58]. Citra digital digunakan dalam berbagai disiplin ilmu, seperti seni, penglihatan manusia, astronomi, dan teknik, serta dapat diproses dan dianalisis menggunakan komputer [59]. Citra dalam perwujudan dapat bermacam-macam, mulai dari gambar perwujudannya dapat bermacam-macam, mulai dari gambar putih pada sebuah foto yang tidak bergerak sampai pada gambar warna yang bergerak pada televisi, proses transformasi dari bentuk tiga dimensi ke bentuk dua dimensi untuk menghasilkan citra akan dipengaruhi oleh bermacam-macam faktor yang mengakibatkan penampilan citra suatu benda tidak sama persis dengan bentuk fisik nyatanya [60]. Citra digital dapat dihasilkan melalui kamera, *scanner*, sensor, atau sistem pencitraan medis dan digunakan secara luas dalam fotografi, kedokteran, keamanan, serta bidang *computer vision*. Pada proses pengolahan citra, citra digital dapat mengalami beberapa

tahapan seperti peningkatan kualitas (*image enhancement*), reduksi *noise*, segmentasi objek, transformasi geometris, serta ekstraksi fitur. Tahapan pengolahan citra digital pada umumnya adalah akuisisi citra, peningkatan kualitas citra, segmentasi citra, ekstraksi fitur citra, dan klasifikasi citra [61].

2.2.4. Open CV

Perpustakaan komputer visi OpenCV (Open Source Computer Vision Library) adalah perpustakaan perangkat lunak sumber terbuka yang menyediakan lebih dari ribuan fungsi untuk pengolahan citra dan visi komputer, termasuk operasi dasar seperti membaca dan menulis gambar, konversi warna, memfilter, transformasi geometris, deteksi fitur, pelacakan objek, kalibrasi kamera, serta antarmuka untuk menjalankan model *machine learning* dan *deep learning* [62]. OpenCV adalah *library* fungsi pemrograman yang terutama digunakan untuk pengolahan citra dan tersedia secara bebas melalui lisensi sumber terbuka Berkeley Software Distribution (BSD) [63]. OpenCV dirancang agar efisien dan mampu beroperasi secara *real-time*, sehingga banyak dimanfaatkan dalam berbagai aplikasi industri, kegiatan penelitian, serta pengembangan prototipe akademik [64].

2.2.5. Python

Bahasa pemrograman Python adalah bahasa pemrograman tingkat tinggi dan merupakan bahasa pemrograman yang sangat populer saat ini [65]. Bahasa ini diciptakan oleh Guido van Rossum di Stichting Mathematisch Centrum (CWI), Amsterdam pada tahun 1991 [66]. Salah satu perbedaan utama Python dengan bahasa pemrograman lainnya adalah pengembangannya melibatkan jutaan *programmer*, peneliti, dan pengguna dari berbagai latar belakang, tidak hanya dari kalangan IT karena python bersifat *open source* [67].

2.2.6. Flask

Dalam pengembangan aplikasi, pemilihan *framework* yang ringan dan fleksibel menjadi salah satu pertimbangan penting. Flask adalah salah satu *microframework* berbasis Python yang digunakan untuk membangun aplikasi web secara sederhana, fleksibel, dan modular [68]. *Framework* ini menyediakan fitur inti yang ringan dan mendukung pengembangan aplikasi secara efisien dengan penggunaan sumber daya yang rendah [69]. Berbeda dengan *framework* yang lebih besar seperti Django, Flask tidak menyediakan struktur baku untuk *autentikasi*, ORM, atau manajemen formulir, sehingga pengembang dapat menyesuaikan aplikasi secara lebih bebas [70]. Flask jauh lebih ringan dan cepat karena dibuat dengan ide menyederhanakan *framework-nya* seminimal mungkin. Dengan

tagline “*web development, one drop at a time*”, Flask mampu membantu pengembang membangun situs dengan sangat cepat meskipun hanya menggunakan pustaka yang sederhana [71].

2.2.7. Google Collaboratory

Layanan Google Collaboratory (Google Colab) adalah aplikasi berbasis web yang disediakan oleh Google dan memungkinkan pengguna untuk menulis, menjalankan, serta membagikan kode Python secara interaktif melalui antarmuka *notebook* [72]. Google Colab menyediakan lingkungan komputasi berbasis *cloud* sehingga pengguna dapat menjalankan kode tanpa perlu melakukan instalasi perangkat lunak di komputer pribadi [73]. Platform ini sangat mendukung berbagai aktivitas seperti pemrosesan data, eksperimen *machine learning*, visualisasi, serta penelitian akademik karena menyediakan akses gratis ke GPU dan TPU untuk mempercepat komputasi [74]. Google Colab sangat menarik perhatian karena memberikan pengguna akses gratis ke layanan GPU sebagai *backend* komputasi yang dapat digunakan hingga 12 jam sekaligus, sehingga bagi pengguna yang ingin belajar Python dan *machine learning* tidak perlu membeli komputer dengan GPU tambahan [75]. Selain itu, Google Colab memudahkan kolaborasi karena *notebook* dapat dibagikan dan disunting bersama secara *real-time* melalui integrasi

dengan Google Drive. Google Colab juga menawarkan fleksibilitas dan *skalabilitas* yang lebih baik dalam pemrosesan data besar [76].

2.2.8. Roboflow


Platform Roboflow merupakan layanan berbasis web yang menyediakan alat untuk mengelola, memproses, dan mempersiapkan *dataset* gambar yang digunakan dalam pelatihan model *computer vision* [77]. Roboflow merupakan platform yang dirancang khusus untuk membantu pengelolaan *dataset* dan berperan penting dalam tahap persiapan data sebelum proses pelatihan model [78]. Roboflow memungkinkan pengguna membagikan dan mengelola *dataset*, melakukan proses *annotate* atau penandaan objek menggunakan *bounding box*, serta menerapkan *pre-processing* pada *dataset* sebagai bagian dari pengolahan data [79]. Dengan menggunakan antarmuka yang intuitif dan otomatisasi berbasis *cloud*, Roboflow memungkinkan pengguna mengelola ribuan gambar tanpa memerlukan perangkat keras khusus [80]. Selain itu, Roboflow menyediakan alat pendukung pengembangan model serta API untuk integrasi aplikasi dan banyak digunakan karena mampu menyederhanakan alur kerja pengembangan model hingga *deployment*.

2.2.9. Diagram Alir

Diagram alir atau *flowchart* merupakan bentuk representasi visual yang digunakan untuk menggambarkan urutan langkah dan logika dari suatu proses atau algoritma menggunakan simbol-simbol tertentu yang saling terhubung melalui garis aliran. *Flowchart* tidak hanya berfungsi sebagai media komunikasi, tetapi juga membantu pemrogram dalam merancang serta mengimplementasikan algoritma secara lebih terstruktur, sehingga dapat mempermudah proses pemecahan masalah, khususnya bagi pemrogram pemula [81]. Setiap tahapan proses digambarkan menggunakan simbol yang memiliki fungsi berbeda dan dihubungkan dengan anak panah untuk menunjukkan arah aliran proses secara berurutan dari awal hingga akhir [82].

Diagram alir banyak dimanfaatkan dalam berbagai bidang, seperti pengembangan perangkat lunak, rekayasa sistem, hingga penelitian ilmiah, karena mampu menyederhanakan proses yang kompleks agar lebih mudah dipahami secara visual [83]. Dalam penelitian ini, *flowchart* digunakan untuk menggambarkan alur kerja sistem, mulai dari proses pengembangan model, proses deteksi objek, hingga proses estimasi berat nasi. Simbol-simbol yang digunakan pada *flowchart* disajikan pada Tabel 2.2.

Tabel 2.2. Simbol *flowchart*

No.	Gambar	Simbol	Keterangan
1.		Proses/Langkah	Menyatakan kegiatan yang akan ditampilkan dalam diagram alir.
2.		Titik Keputusan	Proses/langkah dimana perlu adanya keputusan atau adanya kondisi tertentu. Di titik ini selalu ada dua keluaran untuk melanjutkan kondisi berbeda.
3.		Masukkan/Keluaran Data	Digunakan untuk mewakili data masuk atau data keluar dari suatu proses.
4.		Terminasi	Menunjukkan awal atau akhiran sebuah proses.
5.		Garis Aliran	Menunjukkan arah aliran proses dari satu

			langkah ke langkah berikutnya.
6.		Batas Subproses	Menandai batas wilayah logis dari suatu subproses atau kelompok proses dalam diagram alir untuk memperjelas tahapan yang saling berkaitan.



2.2.10. Diagram Blok

Diagram blok merupakan diagram yang tersusun dari beberapa kotak (blok) dan garis penghubung yang digunakan untuk menjelaskan alur kerja suatu sistem dalam bidang teknik. Diagram ini menggambarkan hubungan antar komponen sistem sehingga proses kerja sistem dapat dipahami dengan lebih mudah. Selain itu, diagram blok juga berfungsi sebagai panduan dalam menjelaskan mekanisme kerja sistem yang akan dibuat serta menjadi rancangan awal dalam proses pengembangan sistem [84].

Dalam penelitian ini, diagram blok digunakan untuk menunjukkan alur kerja sistem estimasi berat dan perhitungan kalori nasi berbasis YOLO26 *segmentation* dan REST API Flask, mulai dari

tahap *input*, proses, hingga *output* sistem. Adapun penjelasan masing-masing komponen pada diagram blok sistem disajikan pada Tabel 2.3.

Tabel 2.3. Komponen Diagram Blok

No.	Simbol	Nama Komponen	Keterangan
1.		Blok	Merepresentasikan sebuah subsistem, modul, fungsi, atau komponen dalam sistem. Diberi label nama fungsi/komponen di dalamnya.
2.		Garis Penghubung	Menunjukkan arah aliran sinyal, data, atau energi antara dua blok. Arah panah menunjukkan arah transmisi informasi.
3.		<i>Input Block</i>	Blok yang menerima sinyal atau data dari luar sistem (misal: sensor MPU6050, PT100, GPS). Biasanya terletak di sisi paling kiri diagram.

4.	Proses	<i>Processing Block</i>	Blok yang melakukan operasi atau transformasi terhadap data (misal: ESP32-S3, FFT, model TinyML). Berada di tengah alur data sistem.
5.	Output	<i>Output Block</i>	Blok yang menghasilkan keluaran akhir sistem (misal: hasil klasifikasi kondisi mesin, data MQTT ke platform monitoring). Terletak di sisi paling kanan diagram.


BAB III

METODOLOGI PENELITIAN

3.1. Prosedur Penelitian

Penelitian ini menggunakan metode *Research and Development* (R&D). Metode R&D merupakan metode penelitian yang bertujuan untuk mengembangkan suatu produk serta menguji kinerja produk yang dihasilkan. Produk yang dikembangkan dalam penelitian ini berupa model deteksi makanan berbasis YOLO yang digunakan sebagai pendukung pemenuhan nutrisi.

Tahapan metode R&D pada penelitian ini dilaksanakan secara bertahap dan sistematis, meliputi analisis kebutuhan, perancangan sistem, pengembangan model, pengujian model, serta evaluasi hasil. Setiap tahapan saling berkaitan untuk menghasilkan model deteksi makanan yang optimal dan sesuai dengan tujuan penelitian. Tahapan metode R&D ditunjukkan pada Gambar 3.1.



Gambar 3.1. Tahapan Metode R&D


Adapun tahapan metode R&D dalam penelitian ini adalah sebagai berikut:

3.1.1. Analisis Kebutuhan

Tahap analisis kebutuhan bertujuan untuk mengidentifikasi kebutuhan penelitian yang berkaitan dengan pengembangan model Yolo. Pada tahap ini dilakukan analisis terhadap kebutuhan *dataset* citra makanan, serta kebutuhan sistem dalam mendeteksi objek makanan, khususnya nasi, sebagai dasar estimasi berat.

3.1.2. Perancangan Sistem

Tahap perancangan sistem dilakukan untuk merancang alur kerja sistem deteksi makanan berbasis YOLO. Perancangan meliputi alur *input* citra dari aplikasi ke server, proses deteksi objek pada model YOLO, serta keluaran berupa label jenis makanan dalam format data terstruktur, sebagaimana ditunjukkan pada Gambar 3.2.




Gambar 3.2. Alur kerja sistem

3.1.3. Pengembangan Model

Tahap pengembangan model merupakan tahap inti dalam

penelitian ini. Pada tahap ini dilakukan proses pengumpulan data citra makanan, *preprocessing* data, serta pelabelan objek makanan menggunakan anotasi *bounding box*. Selanjutnya, model YOLO dilatih menggunakan *dataset* yang telah disiapkan dan dilakukan proses pengujian untuk mengetahui performa model. Proses pelatihan dan pengujian dilakukan secara berulang hingga diperoleh hasil deteksi yang optimal. *Flowchart* pengembangan model ini disajikan pada Gambar 3.3.



Gambar 3.3. *Flowchat* pengembangan model

3.1.4. Pengujian Model

Tahap pengujian model bertujuan untuk mengevaluasi performa model YOLO yang telah dibangun. Pengujian dilakukan dengan memanfaatkan data uji untuk melihat kemampuan model dalam mendeteksi jenis makanan. Hasil pengujian digunakan sebagai dasar untuk menentukan kelayakan model sebelum diterapkan pada sistem berdasarkan nilai *precision*, *recall*, F1-score, dan *mAP* pada data uji untuk menilai akurasi deteksi, serta untuk objek nasi ditambahkan evaluasi estimasi berat terhadap nilai *ground truth* sebagai dasar penentuan kelayakan model.

3.1.5. Penerapan Model

Tahap penerapan model dilakukan setelah proses pengujian model selesai dilakukan. Pada tahap ini, model YOLO yang telah dikembangkan diterapkan ke dalam aplikasi melalui proses integrasi dengan sistem yang telah dirancang. Penerapan model bertujuan agar aplikasi dapat menampilkan hasil deteksi jenis makanan sesuai dengan alur kerja sistem.

3.2. Metode Pengumpulan Data

Metode pengumpulan data meliputi pengumpulan *dataset* citra makanan serta studi literatur yang relevan dengan penelitian.

3.3.1. Pengumpulan *Dataset*


Metode pengumpulan data dalam penelitian ini dilakukan dengan mengumpulkan *dataset* citra makanan yang digunakan sebagai data pelatihan dan pengujian model. Data diperoleh melalui penelusuran *dataset* citra makanan dari media sosial satuan pelayanan pemenuhan gizi (SPPG), serta pengambilan citra secara mandiri menggunakan kamera ponsel. *Dataset* yang digunakan berupa citra digital makanan yang telah diberi label dan anotasi objek sesuai dengan kebutuhan model YOLO. Seluruh data yang telah dikumpulkan kemudian diseleksi dan disesuaikan dengan ruang lingkup penelitian sebelum digunakan pada tahap pelatihan dan evaluasi model.

3.3.2. Studi Literatur

Studi literatur dilakukan dengan mengkaji buku, jurnal ilmiah, dan artikel penelitian yang berkaitan dengan gizi seimbang, *computer vision*, *deep learning*, serta penerapan metode YOLO dalam pengenalan makanan. Studi ini bertujuan untuk memperoleh landasan teori, memahami metode yang relevan, serta mendukung perancangan dan analisis hasil penelitian. 2020 – 2026.

3.3. Waktu Dan Tempat Penelitian

Penelitian ini dilaksanakan pada tanggal 4 Desember 2025 di SPPG AL HIKMAH DEBONG WETAN yang beralamat di Jl. Syekh Abdul Kohar Jl. Syekh Khanan, RT.04/RW.02, Pekauman Kulon, Kecamatan Dukuhturi, Kabupaten Tegal, Jawa Tengah 52192. Lokasi penelitian berdasarkan Google Maps dapat dilihat pada Gambar 3.4.



Gambar 3.4. Lokasi Penelitian

BAB IV

ANALISA DAN PERANCANGAN SISTEM

4.1. Analisa Permasalahan

Permasalahan yang diangkat dalam penelitian ini berkaitan dengan proses pemantauan menu dan porsi makanan pada Program Makan Bergizi Gratis (MBG) yang masih dilakukan secara manual. Proses identifikasi jenis makanan dan penilaian porsi umumnya bergantung pada pengamatan petugas sehingga membutuhkan waktu yang cukup lama serta berpotensi menimbulkan kesalahan dalam pencatatan. Selain itu, metode manual juga kurang efektif apabila diterapkan pada jumlah data yang besar karena sulit dilakukan secara konsisten dan objektif.

Di sisi lain, perkembangan teknologi *computer vision* memungkinkan proses identifikasi objek pada citra digital dilakukan secara otomatis. Namun, implementasi teknologi tersebut pada pemantauan menu makanan masih menghadapi beberapa tantangan, seperti variasi pencahayaan, perbedaan sudut pengambilan gambar, latar belakang yang beragam, serta bentuk makanan yang tidak selalu sama. Kondisi tersebut dapat mempengaruhi kemampuan sistem dalam mengenali objek makanan secara akurat.

Selain proses identifikasi makanan, diperlukan juga metode yang mampu memberikan informasi mengenai porsi makanan, khususnya nasi sebagai sumber karbohidrat utama dalam menu MBG. Oleh karena itu, dibutuhkan suatu sistem yang mampu melakukan deteksi dan segmentasi makanan secara otomatis menggunakan metode YOLO serta memanfaatkan

hasil segmentasi untuk mendukung estimasi berat nasi. Sistem yang dikembangkan juga diharapkan dapat diintegrasikan dalam bentuk REST API sehingga mudah digunakan oleh aplikasi lain dan mendukung proses pemantauan gizi secara lebih cepat, objektif, dan efisien.

4.2. Analisa Kebutuhan Sistem

Analisa kebutuhan sistem dilakukan untuk mengidentifikasi kebutuhan yang diperlukan dalam pengembangan sistem deteksi makanan berbasis YOLO. Kebutuhan tersebut meliputi perangkat keras dan perangkat lunak yang digunakan selama proses pengembangan, pelatihan model, dan pengujian sistem.

4.2.1. Kebutuhan Perangkat Keras

Perangkat keras digunakan untuk mendukung proses pengembangan sistem dan pengambilan data. Adapun perangkat keras yang digunakan adalah sebagai berikut:

1. Komputer dengan spesifikasi:
 - a. Prosesor AMD Ryzen 5 4600G
 - b. RAM 24 GB
2. *Smartphone* Android
 - a. Kamera 50 MP

4.2.2. Kebutuhan Perangkat Lunak

Perangkat lunak yang digunakan dalam penelitian ini adalah sebagai berikut:

1. Google Colaboratory
2. Roboflow
3. Visual Studio Code
4. Postman
5. Google Chrome

4.2.3. Kebutuhan Data

Data yang digunakan dalam penelitian ini berupa *dataset* citra makanan yang terdiri atas gambar menu Program Makan Bergizi Gratis (MBG) dan citra nasi sebagai data referensi untuk proses estimasi berat makanan. *Dataset* menu makanan diperoleh dari media sosial Facebook beberapa Satuan Pelayanan Pemenuhan Gizi (SPPG), yaitu SPPG Babakan Kertajati, SPPG Lawe Loning Aman, SPPG Bima Sape Bugis II, SPPG Sape Bima, dan SPPG Bima Lambu Lanta. Pengumpulan data dilakukan secara manual dengan mengunduh gambar satu per satu dari unggahan yang menampilkan menu makanan.

Data yang diperoleh dari beberapa akun SPPG digunakan sebagai data untuk melatih model yang menampilkan berbagai jenis menu makanan Program Makan Bergizi Gratis (MBG). Variasi jenis

makanan dan kondisi pengambilan gambar pada *dataset* tersebut diharapkan dapat membantu model dalam mengenali objek makanan dengan lebih baik.

Selain *dataset* dari media sosial, penelitian ini juga menggunakan *dataset* citra nasi yang diperoleh melalui pengambilan gambar secara mandiri menggunakan kamera *smartphone* Redmi Note 11 Kamera 50 MP dengan pengaturan kualitas gambar tinggi. Sebelum proses pemotretan dilakukan, nasi terlebih dahulu ditimbang menggunakan timbangan digital dengan berat tetap sebesar 100 gram sebagai data acuan estimasi berat. Pengambilan citra dilakukan sebanyak 100 kali dengan variasi jarak dan posisi pengambilan gambar.


Variasi posisi pengambilan gambar dilakukan dari beberapa sudut yang berbeda, sedangkan variasi jarak dilakukan pada rentang sekitar 20 cm hingga 30 cm dari objek. *Dataset* citra nasi ini digunakan sebagai data referensi untuk menentukan nilai kalibrasi dalam proses estimasi berat makanan. Perhitungan kalibrasi dilakukan menggunakan 100 citra nasi yang telah diketahui berat aktualnya, yaitu 100 gram untuk setiap sampel. Dari hasil perhitungan diperoleh rata-rata luas area segmentasi yang kemudian digunakan sebagai acuan untuk mengestimasi berat makanan berdasarkan luas area objek yang terdeteksi pada citra.

4.3. Perancangan Sistem

Perancangan sistem dilakukan untuk menggambarkan alur kerja sistem deteksi makanan berbasis YOLO yang dikembangkan pada penelitian ini. Perancangan meliputi diagram blok sistem, *flowchart* proses deteksi makanan, serta arsitektur layanan REST API yang digunakan untuk menghubungkan model dengan aplikasi klien.

4.3.1. Perancangan Diagram Blok

Perancangan diagram blok digunakan untuk memberikan gambaran umum mengenai alur kerja sistem mulai dari proses *input* citra hingga menghasilkan keluaran berupa hasil deteksi makanan dan estimasi berat nasi. Diagram blok membantu menjelaskan hubungan antar komponen yang terlibat dalam sistem sehingga memudahkan pemahaman terhadap proses yang berlangsung. Diagram blok sistem dapat dilihat pada Gambar 4.1.



Gambar 4.1. Blok Diagram


Seperti yang di tunjukan pada Gambar 4.1, pengguna mengunggah citra makanan melalui aplikasi klien. Citra kemudian dikirim ke server melalui layanan REST API untuk diproses menggunakan model YOLO26. Hasil deteksi dan segmentasi digunakan untuk mengidentifikasi jenis makanan dan menghitung luas area objek nasi. Selanjutnya sistem melakukan estimasi berat nasi berdasarkan luas area hasil segmentasi dan mengembalikan hasil dalam bentuk data.

4.3.2. Perancangan *Flowchart*

Perancangan *Flowchart* digunakan untuk menggambarkan urutan proses yang dilakukan sistem secara sistematis mulai dari penerimaan citra hingga menghasilkan hasil prediksi.

1. Proses Deteksi Makanan (*Flowchart*)

Pada *Flowchart* deteksi makanan menggambarkan proses identifikasi objek makanan menggunakan model YOLO26. Proses dimulai dari *input* citra, dilanjutkan dengan *preprocessing*, inferensi model, dan menampilkan hasil deteksi objek makanan. *Flowchart* dapat dilihat pada Gambar 4.2.



Gambar 4.2. *Flowchart* deteksi makanan

2. Estimasi Berat Nasi (*Flowchart*)

Pada *Flowchart* estimasi berat nasi menggambarkan proses perhitungan berat nasi berdasarkan luas area hasil segmentasi. Proses dimulai setelah objek nasi berhasil terdeteksi oleh model. Luas area segmentasi dihitung dan dikonversikan menjadi estimasi berat nasi menggunakan nilai kalibrasi yang telah ditentukan. *Flowchart* dapat dilihat pada Gambar 4.3.



Gambar 4.3. *Flowchart* estimasi berat nasi

4.4. Desain *Input/Output*

Desain *input/output* digunakan untuk menggambarkan data yang diterima dan dihasilkan oleh sistem deteksi makanan berbasis YOLO. *Input* sistem berupa citra makanan yang dikirim oleh pengguna melalui aplikasi klien, sedangkan *output* sistem berupa hasil deteksi makanan dan estimasi berat nasi yang diperoleh dari proses inferensi model.

4.4.1. Desain *Input*

Sistem menerima data berupa citra menu makanan yang diperoleh menggunakan kamera *smartphone*. Citra tersebut digunakan sebagai masukan untuk proses deteksi dan segmentasi objek makanan menggunakan model YOLO26. Data yang diterima sistem disajikan pada Tabel 4.1.

Tabel 4.1. Data *Input*

No.	Data <i>Input</i>	Keterangan
1.	Citra menu MBG	Gambar menu makanan yang akan dideteksi dan disegmentasi

4.4.2. Desain *Output*

Sistem menghasilkan informasi berupa hasil deteksi makanan, luas area objek nasi, estimasi berat nasi, serta estimasi kalori nasi berdasarkan citra yang diproses. Informasi tersebut diperoleh dari hasil deteksi dan segmentasi menggunakan model YOLO26 serta perhitungan estimasi berat dan kalori nasi. Data *output* sistem disajikan pada Tabel 4.2.

Tabel 4.2. Data *Output*

No.	Data <i>Output</i>	Keterangan
1.	Jenis makanan	Nama makanan yang berhasil dideteksi
2.	Luas area nasi	Luas objek nasi hasil segmentasi dalam <i>piksel</i>
3.	Berat nasi	Hasil estimasi berat nasi dalam gram
4.	Kalori nasi	Hasil estimasi kalori nasi dalam kilokalori (<i>kcal</i>)

BAB V

HASIL DAN PEMBAHASAN


5.1. Implementasi Sistem

Implementasi sistem merupakan tahap penerapan hasil perancangan yang telah dilakukan pada bab sebelumnya. Pada tahap ini dilakukan implementasi *dataset*, pelatihan model YOLO26, layanan REST API, serta pengujian antarmuka yang digunakan untuk menampilkan hasil deteksi makanan dan estimasi berat nasi.

5.1.1. Implementasi *Dataset*

Data yang digunakan pada penelitian ini terdiri dari dua jenis data, yaitu *dataset* menu makanan dan *dataset* nasi. *Dataset* menu makanan digunakan untuk melatih model dalam mendeteksi dan melakukan segmentasi objek makanan pada menu Makan Bergizi Gratis (MBG), sedangkan *dataset* nasi digunakan sebagai data acuan dalam proses estimasi berat nasi.


Kumpulan data makanan diperoleh dari media sosial Satuan Pelayanan Pemenuhan Gizi (SPPG) dan telah melalui proses anotasi menggunakan platform Roboflow. *Dataset* ini terdiri dari berbagai variasi menu MBG yang memuat beberapa kategori makanan seperti nasi, protein, sayur, buah, karbohidrat, dan susu. Implementasi *dataset* makanan yang digunakan dalam penelitian ini dapat dilihat pada Gambar 5.1.



Gambar 5.1. *Dataset Menu MBG*

Berdasarkan Gambar 5.1, *dataset* makanan terdiri dari berbagai jenis menu makanan dengan bentuk, ukuran, dan susunan yang berbeda sehingga dapat membantu model mempelajari karakteristik setiap objek makanan pada berbagai kondisi penyajian.

Selain *dataset* makanan, penelitian ini juga menggunakan *dataset* nasi sebagai acuan dalam proses estimasi berat nasi. *Dataset* nasi terdiri dari 100 citra yang diperoleh melalui pengambilan gambar menggunakan kamera *smartphone* dan dianotasi menggunakan metode segmentasi. *Dataset* ini digunakan untuk memperoleh hubungan antara luas area objek nasi dan berat aktual yang diperoleh melalui proses penimbangan. Implementasi *dataset* nasi yang digunakan dalam penelitian ini dapat dilihat pada Gambar 5.2.



Gambar 5.2. *Dataset* Nasi untuk Estimasi Berat

Berdasarkan Gambar 5.2, *dataset* nasi digunakan sebagai data acuan untuk menentukan nilai kalibrasi yang digunakan dalam proses estimasi berat nasi berdasarkan luas area hasil segmentasi.

Proses implementasi *dataset* makanan pada penelitian ini meliputi tahap *preprocessing dataset* dan *augmentasi* data sebelum digunakan pada proses pelatihan model.

1. Praproses Data (*Preprocessing Dataset*)

Jumlah *dataset* makanan yang digunakan dalam penelitian ini sebanyak 505 citra. *Dataset* kemudian dibagi menjadi data pelatihan (*train*), data validasi (*validation*), dan data pengujian (*test*) menggunakan rasio 80:10:10. Pembagian *dataset* dilakukan untuk memastikan model dapat dilatih dan dievaluasi menggunakan data yang berbeda. Pembagian *dataset* dapat dilihat pada Tabel 5.1.

Tabel 5.1. Pembagian *dataset* Makanan


No.	Jenis Data	Jumlah
1.	<i>Train</i>	404
2.	<i>Validation</i>	51
3.	<i>Test</i>	50
Total		505

Berdasarkan Tabel 5.1, sebanyak 404 citra digunakan sebagai data pelatihan, 51 citra digunakan sebagai data validasi, dan 50 citra digunakan sebagai data pengujian. Sebagian besar data dialokasikan untuk proses pelatihan agar model dapat mempelajari karakteristik objek makanan secara optimal.

Sebelum digunakan pada proses pelatihan model, *dataset* terlebih dahulu melalui tahap *preprocessing* menggunakan platform Roboflow. *Preprocessing* yang diterapkan meliputi *Auto-Orient* dan *Resize* menggunakan metode *Fit Within* dengan resolusi 640×640 *piksel*. *Auto-Orient* digunakan untuk memastikan seluruh citra memiliki orientasi yang konsisten dengan mengoreksi orientasi gambar berdasarkan *metadata* yang tersimpan pada citra. Konsistensi orientasi penting dalam pengolahan citra karena orientasi yang tidak sesuai dapat memengaruhi representasi fitur yang dipelajari model selama proses pelatihan. Langkah ini dilakukan untuk mengurangi variasi data yang tidak berkaitan dengan objek penelitian sehingga proses pembelajaran model dapat berlangsung lebih optimal [85].

Selain itu, dilakukan *Resize* untuk menyeragamkan dimensi citra sehingga seluruh data memiliki ukuran *input* yang konsisten selama proses pelatihan model. Penyeragaman ukuran citra diperlukan karena model deteksi objek berbasis YOLO menggunakan ukuran *input* tertentu pada proses pelatihan. Hashemi menyatakan bahwa citra perlu diubah ke ukuran yang sama agar dapat diproses secara konsisten oleh model *deep learning* [86]. Pada penelitian ini digunakan resolusi 640×640 piksel karena sesuai dengan konfigurasi pelatihan model YOLO26, di mana seluruh model dasar YOLO26 dilatih menggunakan resolusi 640×640 pada *dataset* COCO.

Tahapan ini bertujuan untuk menghasilkan *dataset* yang lebih seragam dan konsisten sehingga dapat mendukung proses pelatihan model secara optimal. Perbandingan citra sebelum dan sesudah proses *preprocessing* dapat dilihat pada Gambar 5.3.



Gambar 5.3. Perbandingan Sebelum dan Sesudah *Preprocessing*

Berdasarkan Gambar 5.3, *preprocessing* yang dilakukan menghasilkan citra dengan orientasi dan ukuran yang lebih seragam dibandingkan sebelum *preprocessing*. Hasil tersebut membantu menciptakan *dataset* yang lebih konsisten siap dan digunakan pada proses pelatihan model.

Untuk *dataset* makanan terdiri dari enam kelas objek yang digunakan dalam proses deteksi dan segmentasi. Jumlah anotasi pada masing-masing kelas dapat dilihat pada Tabel 5.2.

Tabel 5.2. Jumlah Anotasi Setiap Kelas

No.	Kelas	Jumlah Anotasi
1.	Protein	2551
2.	Buah	2175
3.	Sayur	1614
4.	Nasi	1423
5.	Karbo	198
6.	Susu	193


Berdasarkan Tabel 5.2, kelas protein memiliki jumlah anotasi terbanyak yaitu 2.551 anotasi, sedangkan kelas susu memiliki jumlah anotasi paling sedikit yaitu 193 anotasi.

2. Penambahan Variasi Data (*Augmentasi Data*)

Perbedaan jumlah anotasi antar kelas menunjukkan bahwa distribusi data yang digunakan belum sepenuhnya seimbang. Kondisi tersebut dapat memengaruhi kemampuan model dalam mempelajari

karakteristik setiap kelas objek secara merata. Oleh karena itu, dilakukan *augmentasi* data untuk meningkatkan keragaman data pelatihan sehingga model dapat mengenali objek makanan pada berbagai kondisi citra.


Pada tahap pembuatan versi *dataset* di Roboflow, diterapkan teknik *augmentasi* data dengan menghasilkan tiga variasi citra untuk setiap data pelatihan (*Maximum Version Size* = 3×) serta menambahkan *Salt and Pepper Noise* sebesar 0,2% *piksel*. Pemilihan tingkat *Salt and Pepper Noise* sebesar 0,2% (*noise density* = 0,002) didasarkan pada penelitian oleh Wang et al., yang menggunakan nilai tersebut sebagai representasi gangguan impuls ringan pada citra. Tingkat *noise* ini dinilai mampu meningkatkan variasi data tanpa menghilangkan informasi visual utama yang diperlukan dalam proses pelatihan model [87]. *Augmentasi* dilakukan untuk memperkaya keragaman data pelatihan tanpa mengubah karakteristik utama objek makanan yang menjadi fokus pengenalan. Dengan jumlah data pelatihan sebanyak 404 citra, proses *augmentasi* menghasilkan sekitar 1.212 citra yang digunakan dalam pelatihan model. Perbandingan citra sebelum dan sesudah proses *augmentasi* ditunjukkan pada Gambar 5.4.



Gambar 5.4. Perbandingan Sebelum dan Sesudah *Augmentasi*

Berdasarkan Gambar 5.4, proses *augmentasi* dilakukan dengan menambahkan *Salt and Pepper Noise* sebesar 0,2% pada citra pelatihan. Penambahan *noise* menghasilkan variasi citra baru berupa titik-titik *piksel* acak yang tersebar pada beberapa bagian gambar. Meskipun demikian, objek makanan pada citra tetap terlihat dengan jelas sehingga informasi utama yang diperlukan dalam proses deteksi dan segmentasi tidak mengalami perubahan yang signifikan. *Augmentasi* ini bertujuan untuk meningkatkan keragaman data pelatihan agar model lebih tangguh terhadap variasi kualitas citra yang mungkin ditemui pada data pengujian maupun implementasi nyata.

Untuk melihat pengaruh *augmentasi* terhadap distribusi intensitas *piksel*, dilakukan perbandingan histogram antara citra sebelum dan sesudah *augmentasi*. Perbandingan tersebut dapat dilihat pada Gambar 5.5.



Gambar 5.5. Histogram Sebelum dan Sesudah *Augmentasi*

Berdasarkan Gambar 5.5, distribusi intensitas *piksel* sebelum dan sesudah *augmentasi* menunjukkan pola yang relatif serupa. Perbedaan kecil pada beberapa bagian kurva histogram menunjukkan adanya perubahan nilai intensitas *piksel* akibat penambahan *Salt and Pepper Noise* sebesar 0,2%. Meskipun terjadi perubahan pada sejumlah *piksel*, karakteristik utama citra tetap dipertahankan sehingga objek makanan masih dapat dikenali dengan baik. Hasil ini menunjukkan bahwa proses *augmentasi* mampu menghasilkan variasi data baru tanpa mengubah informasi penting yang terdapat pada citra.

Distribusi anotasi pada *dataset* yang digunakan dalam penelitian ini dapat dilihat pada Tabel 5.3.

Tabel 5.3. Distribusi Anotasi *Dataset*

No.	Kelas	<i>Train</i>	<i>Validation</i>	<i>Test</i>	Total
1	Buah	5127	227	239	5593
2	Karbo	447	19	30	496
3	Nasi	3416	144	141	3701
4	Protein	6234	238	235	6707
5	Sayur	3921	144	163	4228
6	Susu	498	17	10	525
Total		19643	789	818	21250

Berdasarkan Tabel 5.3, jumlah anotasi pada data pelatihan sebanyak 19.643 anotasi, sedangkan pada data validasi dan data pengujian masing-masing sebanyak 789 dan 818 anotasi. Jumlah anotasi tersebut digunakan untuk membantu model mempelajari karakteristik setiap objek makanan pada proses pelatihan. Hasil *augmentasi* menghasilkan variasi data yang lebih beragam sehingga dapat meningkatkan kemampuan generalisasi model dalam mendeteksi dan melakukan segmentasi objek makanan pada kondisi citra yang berbeda.

5.1.2. Implementasi Pelatihan Model

Pelatihan model dilakukan untuk menghasilkan model yang mampu mendeteksi dan melakukan segmentasi objek makanan pada menu Makan Bergizi Gratis (MBG). Proses pelatihan dilakukan menggunakan platform Google Colaboratory dengan memanfaatkan GPU T4 untuk mempercepat proses komputasi. Model yang digunakan dalam penelitian ini adalah YOLO26n-Seg yang dilatih menggunakan *dataset* makanan yang telah dipersiapkan pada tahap sebelumnya.

Sebelum proses pelatihan dilakukan, *dataset* yang telah dianotasi dan diproses menggunakan Roboflow diekspor ke format YOLO Segmentasi kemudian diunggah ke Google Colaboratory. Selanjutnya dilakukan konfigurasi parameter pelatihan sesuai dengan

kebutuhan penelitian. Konfigurasi pelatihan model yang digunakan dapat dilihat pada Tabel 5.4.

Tabel 5.4. Konfigurasi Pelatihan Model

No.	Parameter	Nilai	Keterangan
1	Model	YOLO 26n-Seg	Model segmentasi yang digunakan untuk mendeteksi dan melakukan segmentasi objek makanan.
2	<i>Epoch</i>	100	Jumlah pengulangan proses pelatihan terhadap seluruh <i>dataset</i> .
3	<i>Image Size</i>	640×640	Ukuran citra yang digunakan selama proses pelatihan.
4	<i>Batch Size</i>	16	Jumlah citra yang diproses dalam satu iterasi pelatihan.
5	<i>Cache</i>	<i>True</i>	Menyimpan <i>dataset</i> ke memori agar proses pelatihan lebih cepat.
6	<i>Save Period</i>	10	Menyimpan hasil pelatihan setiap 10 <i>epoch</i> .
7	<i>Device</i>	0 (GPU T4)	Perangkat komputasi yang digunakan selama proses pelatihan.
8	<i>Copy Paste</i>	0,5	Menyalin objek ke area lain untuk menambah variasi data.
9	<i>Rotation</i>	15°	Merotasi citra untuk meningkatkan variasi orientasi objek.
10	<i>Scale</i>	0,5	Mengubah ukuran objek untuk meningkatkan variasi skala.
11	<i>Horizontal Flip</i>	0,5	Membalik citra secara horizontal dengan probabilitas 50%.

Berdasarkan Tabel 5.4, model dilatih menggunakan YOLO26n-Seg selama 100 *epoch* dengan ukuran citra 640×640 piksel dan *batch size* sebesar 16. Ukuran citra 640×640 dipilih karena merupakan ukuran *input* yang digunakan pada pelatihan model dasar YOLO26, sedangkan *batch size* 16 disesuaikan dengan kapasitas memori GPU yang digunakan selama proses pelatihan. Selain parameter utama tersebut, proses pelatihan juga memanfaatkan *augmentasi* bawaan

YOLO yang diterapkan secara dinamis pada setiap *epoch*. Berbeda dengan *augmentasi* pada *Roboflow* yang menghasilkan penambahan data secara permanen sebelum pelatihan, *augmentasi* pada YOLO dilakukan secara langsung selama proses pelatihan sehingga setiap citra dapat mengalami variasi transformasi yang berbeda pada setiap iterasi.

Parameter *augmentasi* yang digunakan mengacu pada konfigurasi *augmentasi* yang direkomendasikan dalam dokumentasi Ultralytics YOLO, yaitu *Copy Paste* sebesar 0,5, *Rotation* sebesar 15° , *Scale* sebesar 0,5, dan *Horizontal Flip* sebesar 0,5. *Augmentasi Copy Paste* digunakan untuk menyalin objek ke area lain pada citra sehingga variasi posisi dan distribusi objek menjadi lebih beragam. *Augmentasi Rotation* sebesar 15° diterapkan untuk mensimulasikan variasi orientasi objek akibat perbedaan sudut pengambilan gambar. *Augmentasi Scale* sebesar 0,5 digunakan untuk menghasilkan variasi ukuran objek sehingga model mampu mengenali objek pada berbagai skala. Selain itu, *Horizontal Flip* sebesar 0,5 diterapkan dengan probabilitas 50% untuk meningkatkan kemampuan model dalam mengenali objek pada orientasi yang berbeda.

Penerapan *augmentasi* tersebut bertujuan untuk meningkatkan keragaman data pelatihan dan mengurangi risiko *overfitting* sehingga model memiliki kemampuan generalisasi yang lebih baik terhadap data baru. Dengan demikian, model diharapkan mampu mendeteksi

dan melakukan segmentasi objek makanan secara lebih akurat pada berbagai kondisi citra.


Selama proses pelatihan, model melakukan pembelajaran menggunakan data pelatihan dan dievaluasi menggunakan data validasi pada setiap *epoch*. Hasil pelatihan kemudian menghasilkan model terbaik berdasarkan performa pada data validasi. Model terbaik tersebut selanjutnya digunakan pada tahap pengujian untuk melakukan deteksi dan segmentasi objek makanan serta mendukung proses estimasi berat nasi berdasarkan luas area hasil segmentasi.

5.1.3. Implementasi REST API

Sebagai penghubung antara aplikasi klien dan model YOLO26 yang berjalan pada server, diimplementasikan layanan REST API. Layanan ini dibangun menggunakan *framework* Flask sehingga proses pertukaran data antara pengguna dan sistem dapat dilakukan melalui protokol HTTP.

Pada penelitian ini digunakan satu *endpoint* utama, yaitu */predict* dengan metode POST. *Endpoint* tersebut berfungsi untuk menerima citra makanan yang dikirim oleh pengguna, kemudian memproses citra menggunakan model YOLO26 untuk melakukan deteksi dan segmentasi objek makanan. Hasil segmentasi objek nasi selanjutnya digunakan untuk menghitung estimasi berat nasi berdasarkan nilai kalibrasi yang telah ditentukan sebelumnya.

Setelah proses prediksi selesai, sistem mengembalikan hasil berupa informasi objek makanan yang terdeteksi serta estimasi berat nasi dalam format JSON. Contoh respons yang dihasilkan oleh sistem dapat dilihat pada Gambar 5.2.



Gambar 5.6. Hasil Respons REST API

Berdasarkan Gambar 5.2, sistem berhasil mengembalikan informasi berupa jenis makanan yang terdeteksi, luas area objek nasi hasil segmentasi, serta estimasi berat nasi yang dihitung berdasarkan luas area tersebut. Data dalam format JSON memungkinkan hasil prediksi diintegrasikan dengan berbagai aplikasi yang membutuhkan layanan deteksi makanan secara otomatis.

5.1.4. Implementasi Hasil Deteksi dan Estimasi Berat

Implementasi hasil deteksi dan estimasi berat dilakukan untuk menampilkan keluaran yang dihasilkan oleh sistem setelah citra

makanan diproses menggunakan model YOLO26. Keluaran sistem meliputi hasil deteksi makanan, hasil segmentasi objek nasi, dan estimasi berat nasi berdasarkan luas area hasil segmentasi.

1. Hasil Deteksi Dan Segmentasi Nasi

Hasil deteksi dan segmentasi makanan merupakan keluaran utama yang dihasilkan oleh model YOLO26 Segmentasi. Pada tahap ini sistem mengidentifikasi objek makanan yang terdapat pada citra sekaligus menghasilkan area segmentasi yang mengikuti bentuk objek. Informasi tersebut digunakan untuk mengetahui jenis makanan yang terdeteksi dan menghitung luas area objek nasi. Implementasi hasil deteksi dan segmentasi makanan dapat dilihat pada Gambar 5.3.



Gambar 5.7. Hasil Deteksi dan Segmentasi Makanan

Berdasarkan Gambar 5.3, sistem berhasil mendeteksi objek makanan yang terdapat pada citra dan menghasilkan area segmentasi pada setiap objek yang terdeteksi. Hasil segmentasi tersebut digunakan sebagai dasar untuk menghitung luas area objek nasi pada proses estimasi berat.

2. Estimasi Berat Nasi

Setelah diperoleh luas area objek nasi dalam satuan *piksel* dari hasil segmentasi, langkah berikutnya adalah melakukan proses kalibrasi untuk memperoleh hubungan antara luas area objek dan berat aktual nasi.

Perhitungan kalibrasi dilakukan menggunakan data referensi sebanyak 100 citra nasi yang telah diketahui berat aktualnya, yaitu 100 gram untuk setiap sampel. Dari hasil perhitungan diperoleh rata-rata luas area segmentasi sebesar 896.172,60 *piksel*.

Nilai kalibrasi diperoleh dengan membagi berat aktual nasi terhadap rata-rata luas area segmentasi menggunakan Persamaan di bawah:

$$\begin{aligned}
 \text{Kalibrasi} &= \frac{\text{Berat Aktual (gram)}}{\text{Rata – rata Luas Area (piksel)}} \\
 &= \frac{100 \text{ gram}}{896.172,60 \text{ pixel}} \\
 &= 0,00011159 \text{ gram/piksel}
 \end{aligned}$$

Maka diperoleh nilai kalibrasi sebesar:

$$1 \text{ Piksel} = 0,00011159 \text{ gram}$$

Setelah diperoleh nilai kalibrasi, langkah berikutnya adalah menghitung estimasi berat nasi berdasarkan luas area hasil segmentasi. Perhitungan estimasi berat nasi dapat dituliskan menggunakan Persamaan:

$$\text{Berat Nasi (gram)} = \text{Luas Area (piksel)} \times 0,00011159$$

Dari persamaan tersebut, sistem dapat mengonversi luas area objek nasi hasil segmentasi menjadi estimasi berat nasi dalam satuan gram. Hasil estimasi berat tersebut kemudian digunakan untuk menghitung jumlah kalori nasi berdasarkan nilai kalori per gram. Berdasarkan data dari Fastsecret, 100 gram nasi putih mengandung 129 kalori, sehingga setiap 1 gram nasi setara dengan 1,29 kalori.

5.2. Hasil Pengujian


Hasil pengujian dilakukan untuk mengetahui kemampuan model YOLO26 Segmentasi dalam mendeteksi dan melakukan segmentasi objek makanan pada menu Makan Bergizi Gratis (MBG). Pengujian dilakukan menggunakan tiga skenario data uji yang terdiri dari 50 citra, 115 citra, dan 690 citra. Penggunaan jumlah data yang berbeda bertujuan untuk mengevaluasi konsistensi performa model terhadap variasi jumlah data dan

kondisi citra yang semakin beragam. Selain itu, pengujian juga dilakukan untuk mengetahui kemampuan sistem dalam melakukan estimasi berat nasi berdasarkan luas area hasil segmentasi.

Berdasarkan hasil *training* dan validasi selama 100 *epoch*, model YOLO26 Segmentasi memperoleh nilai *precision* sebesar 0,798, *recall* sebesar 0,902, dan mAP50 sebesar 0,927 pada deteksi *bounding box*. Pada segmentasi *mask*, model memperoleh *precision* sebesar 0,797, *recall* sebesar 0,900, dan mAP50 sebesar 0,921. Hasil tersebut menunjukkan bahwa model memiliki kemampuan yang baik dalam mendeteksi dan melakukan segmentasi objek makanan. Adapun hasil pengujian menggunakan data uji ditunjukkan pada uraian berikut.

5.2.1. Pengujian Performa Model

Pengujian performa model dilakukan untuk mengetahui kemampuan model YOLO26 Segmentasi dalam mendeteksi dan melakukan segmentasi objek makanan pada berbagai jumlah data pengujian. Evaluasi dilakukan menggunakan metrik *Precision*, *Recall*, mAP50, dan mAP50-95 yang merupakan metrik standar dalam pengukuran performa model deteksi objek dan segmentasi. Hasil evaluasi model pada masing-masing skenario pengujian disajikan pada Tabel 5.8.



Gambar 5.8. Hasil Evaluasi Model

Berdasarkan Gambar 5.8, performa terbaik diperoleh pada pengujian menggunakan 50 citra dengan nilai mAP50 sebesar 89,2% pada deteksi objek dan 88,6% pada segmentasi objek. Ketika jumlah data pengujian ditingkatkan menjadi 115 citra dan 690 citra, nilai *precision*, *recall*, dan *mAP* mengalami penurunan. Hal ini menunjukkan bahwa semakin besar dan beragam data yang digunakan untuk pengujian, semakin tinggi tingkat kesulitan yang dihadapi model dalam melakukan deteksi dan segmentasi objek makanan.

Meskipun demikian, pada pengujian menggunakan 690 citra model masih mampu memperoleh nilai mAP50 sebesar 78,0% pada deteksi objek dan 77,5% pada segmentasi objek. Hasil tersebut menunjukkan bahwa model tetap memiliki kemampuan yang cukup


baik dalam mengenali objek makanan pada data yang lebih beragam sehingga kemampuan generalisasi model dapat dikatakan cukup baik.

5.2.2. Pengujian Evaluasi Model

Pengujian evaluasi model dilakukan untuk mengetahui kemampuan model YOLO26 Segmentasi dalam mendeteksi dan mengklasifikasikan objek makanan pada data pengujian. Evaluasi dilakukan menggunakan *confusion matrix*, *precision-recall curve*, dan *F1-confidence curve*. Pengujian ini bertujuan untuk melihat tingkat ketepatan klasifikasi, hubungan antara *precision* dan *recall*, serta nilai *confidence* yang menghasilkan performa terbaik pada model.

1. *Confusion Matrix*

Confusion matrix digunakan untuk mengetahui tingkat keberhasilan model dalam mengklasifikasikan setiap kelas objek makanan. Matriks ini menunjukkan hubungan antara kelas aktual dan kelas hasil prediksi sehingga dapat diketahui kelas yang paling sering terdeteksi dengan benar maupun kelas yang masih mengalami kesalahan klasifikasi. Hasil *confusion matrix* pada pengujian menggunakan 50 citra, 115 citra, dan 690 citra dapat dilihat pada Gambar 5.8.


Gambar 5.9. *Confusion matrix*

Berdasarkan Gambar 5.8, sebagian besar prediksi pada ketiga *confusion matrix* berada pada diagonal matriks yang menunjukkan bahwa model mampu mengklasifikasikan objek sesuai dengan kelas sebenarnya. Pada pengujian menggunakan 50 citra (a), objek buah terklasifikasi benar sebanyak 209 data, nasi sebanyak 132 data, protein sebanyak 193 data, sayur sebanyak 129 data, karbo sebanyak 24 data, dan susu sebanyak 10 data. Pada pengujian menggunakan 115 citra (b), jumlah prediksi benar meningkat menjadi 209 data untuk buah, 102 data untuk nasi, 226 data untuk protein, 140 data untuk sayur, 7 data untuk karbo, dan

19 data untuk susu. Sementara itu, pada pengujian menggunakan 690 citra (c), jumlah prediksi benar mencapai 1.309 data untuk buah, 570 data untuk nasi, 1.162 data untuk protein, 841 data untuk sayur, 64 data untuk karbo, dan 123 data untuk susu.

Secara umum, hasil *confusion matrix* menunjukkan bahwa model memiliki kemampuan klasifikasi yang baik pada seluruh skenario pengujian. Meskipun masih terdapat beberapa kesalahan prediksi antar kelas serta sejumlah objek yang terdeteksi sebagai *background*, sebagian besar objek makanan berhasil diklasifikasikan dengan benar. Khusus pada kelas nasi yang menjadi fokus penelitian, model mampu mempertahankan jumlah prediksi benar yang tinggi pada seluruh jumlah data pengujian, menunjukkan bahwa model memiliki kemampuan yang baik dalam mengenali objek nasi pada berbagai kondisi citra.

Untuk memberikan gambaran yang lebih jelas mengenai proporsi keberhasilan klasifikasi pada setiap kelas, dilakukan normalisasi *confusion matrix* sebagaimana ditunjukkan pada Gambar 5.9.



Gambar 5.10. normalisasi *confusion matrix*

Berdasarkan Gambar 5.9, sebagian besar nilai pada diagonal matriks berada pada kategori yang tinggi, yang menunjukkan bahwa model mampu mengklasifikasikan objek sesuai dengan kelas sebenarnya pada ketiga skenario pengujian. Pada pengujian menggunakan 50 citra, kelas nasi memperoleh tingkat keberhasilan klasifikasi sebesar 0,94 atau 94%. Nilai tersebut meningkat menjadi 0,99 atau 99% pada pengujian menggunakan 115 citra dan mencapai 0,98 atau 98% pada pengujian menggunakan 690 citra.


Hasil tersebut menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam mengenali objek nasi secara konsisten meskipun jumlah data pengujian terus bertambah. Tingginya nilai klasifikasi pada kelas nasi menunjukkan bahwa sebagian besar objek nasi berhasil diklasifikasikan dengan benar dan hanya sebagian kecil yang mengalami kesalahan prediksi. Kondisi ini menunjukkan bahwa model memiliki kemampuan generalisasi yang baik terhadap variasi bentuk, ukuran, dan kondisi pencahayaan objek nasi pada berbagai citra pengujian.

Selain kelas nasi, beberapa kelas lain seperti buah dan susu juga menunjukkan tingkat keberhasilan klasifikasi yang tinggi. Namun demikian, masih terdapat beberapa kesalahan prediksi pada kelas tertentu, terutama kelas karbo, protein, dan sayur. Pada kelas karbo, kesalahan prediksi dapat dipengaruhi oleh tingginya variasi jenis makanan yang termasuk dalam kategori karbohidrat, seperti kentang, mi, bihun, jagung, dan olahan karbohidrat lainnya yang memiliki bentuk, warna, serta tekstur yang berbeda-beda. Sementara itu, kelas protein dan sayur juga memiliki keragaman visual yang cukup tinggi sehingga meningkatkan kemungkinan terjadinya kesalahan klasifikasi. Secara keseluruhan, hasil normalisasi *confusion matrix* menunjukkan bahwa model mampu melakukan klasifikasi objek makanan

dengan baik, khususnya pada kelas nasi yang menjadi fokus utama penelitian ini.

2. *Precision-Recall Curve*

Precision-Recall Curve digunakan untuk mengevaluasi hubungan antara nilai *precision* dan *recall* yang dihasilkan oleh model. Kurva ini menunjukkan kemampuan model dalam mempertahankan nilai *precision* ketika *recall* meningkat. Semakin luas area di bawah kurva, semakin baik kemampuan model dalam mendeteksi dan melakukan segmentasi objek. Hasil *Precision-Recall Curve* pada pengujian menggunakan 50 citra, 115 citra, dan 690 citra dapat dilihat pada Gambar 5.10.



Gambar 5.11. *Precision-Recall Curve*

Berdasarkan Gambar 5.10, model menunjukkan performa yang baik pada ketiga skenario pengujian. Nilai $mAP@50$ keseluruhan yang diperoleh masing-masing sebesar 0,886 pada pengujian menggunakan 50 citra, 0,783 pada pengujian menggunakan 115 citra, dan 0,775 pada pengujian menggunakan 690 citra. Perbedaan nilai tersebut menunjukkan bahwa semakin banyak dan beragam data pengujian yang digunakan, semakin besar tantangan yang dihadapi model dalam melakukan segmentasi objek makanan.

Pada kelas nasi yang menjadi fokus penelitian, nilai *Average Precision* (AP) yang diperoleh tetap berada pada kategori sangat tinggi pada seluruh skenario pengujian. Pengujian menggunakan 50 citra menghasilkan AP sebesar 0,963, kemudian meningkat menjadi 0,983 pada pengujian menggunakan 115 citra, dan mencapai 0,986 pada pengujian menggunakan 690 citra. Hasil tersebut menunjukkan bahwa model mampu melakukan segmentasi objek nasi secara akurat dan konsisten meskipun jumlah data pengujian meningkat secara signifikan.

Selain kelas nasi, kelas susu juga menunjukkan performa yang sangat baik dengan nilai AP sebesar 0,995 pada pengujian 50 citra, 0,901 pada pengujian 115 citra, dan 0,946 pada pengujian 690 citra. Sementara itu, kelas buah memperoleh nilai AP sebesar 0,909, 0,853, dan 0,880 pada masing-masing


pengujian. Sebaliknya, kelas karbo memiliki nilai AP yang relatif lebih rendah dibandingkan kelas lainnya, yaitu sebesar 0,789, 0,291, dan 0,224. Kondisi ini diduga dipengaruhi oleh tingginya variasi objek yang termasuk dalam kategori karbohidrat, sehingga model lebih sulit mempelajari karakteristik visual yang konsisten pada kelas tersebut.

Secara keseluruhan, kurva *Precision-Recall* menunjukkan bahwa model memiliki kemampuan segmentasi yang baik pada sebagian besar kelas objek makanan. Tingginya nilai AP pada kelas nasi pada seluruh skenario pengujian menunjukkan bahwa model mampu menghasilkan segmentasi yang akurat dan stabil. Hasil tersebut mendukung tujuan utama penelitian, yaitu melakukan segmentasi nasi sebagai dasar dalam proses estimasi berat nasi.

3. *F1-Confidence Curve*

F1-Confidence Curve digunakan untuk menentukan nilai *confidence threshold* yang menghasilkan keseimbangan terbaik antara *precision* dan *recall*. Nilai F1-score merupakan kombinasi antara *precision* dan *recall*, sehingga dapat digunakan untuk mengevaluasi performa model secara keseluruhan. Semakin tinggi nilai F1-score yang diperoleh, semakin baik kemampuan model dalam mendeteksi dan melakukan segmentasi objek secara

akurat. Hasil pengujian *F1-Confidence Curve* pada pengujian menggunakan 50 citra, 115 citra, dan 690 citra dapat dilihat pada Gambar 5.11.



Gambar 5.12. *F1-Confidence Curve*

Berdasarkan Gambar 5.11, nilai F1-score tertinggi untuk seluruh kelas pada pengujian menggunakan 50 citra diperoleh sebesar 0,81 pada *confidence threshold* 0,435. Pada pengujian menggunakan 115 citra, nilai F1-score tertinggi sebesar 0,77 diperoleh pada *confidence threshold* 0,493. Sementara itu, pada pengujian menggunakan 690 citra, nilai F1-score tertinggi sebesar 0,75 diperoleh pada *confidence threshold* 0,569.

Hasil tersebut menunjukkan bahwa nilai *confidence threshold* optimal cenderung meningkat seiring bertambahnya jumlah data pengujian. Meskipun nilai F1-score mengalami sedikit penurunan pada pengujian dengan jumlah data yang lebih besar, performa model tetap berada pada kategori yang cukup baik dengan nilai F1-score di atas 0,75 pada seluruh skenario pengujian. Kondisi ini menunjukkan bahwa model mampu mempertahankan keseimbangan antara *precision* dan *recall* meskipun dihadapkan pada variasi data yang lebih beragam.

Jika ditinjau dari kelas nasi yang menjadi fokus penelitian, kurva F1 menunjukkan performa yang stabil dan berada pada nilai yang tinggi pada ketiga skenario pengujian. Hasil tersebut menunjukkan bahwa model mampu melakukan deteksi dan segmentasi objek nasi secara konsisten pada berbagai nilai *confidence threshold*. Kemampuan ini menjadi penting karena kualitas segmentasi nasi akan memengaruhi proses estimasi berat nasi yang dilakukan pada tahap selanjutnya.

Secara keseluruhan, hasil F1-Confidence *Curve* menunjukkan bahwa model memiliki performa yang stabil pada berbagai jumlah data pengujian. Nilai *confidence threshold* optimal yang diperoleh dapat digunakan sebagai acuan dalam implementasi sistem untuk memperoleh keseimbangan terbaik

antara *precision* dan *recall*, sehingga hasil deteksi dan segmentasi objek makanan dapat dilakukan secara lebih baik.

5.2.3. Pengujian Estimasi Berat Nasi

Pengujian estimasi berat nasi dilakukan untuk mengetahui kemampuan sistem dalam memperkirakan berat nasi berdasarkan luas area hasil segmentasi. Pengujian dilakukan dengan membandingkan berat aktual nasi hasil penimbangan dengan berat estimasi yang dihitung menggunakan nilai kalibrasi sebesar 0,00011159 gram/*piksel*. Hasil pengujian estimasi berat nasi disajikan pada Tabel 5.7.

Tabel 5.5. Hasil Pengujian Estimasi Berat Nasi

No.	Berat Aktual (gram)	Berat Estimasi (gram)	Selisih (gram)
1.	100	107	7
		133	33
		117	17
2.	150	156	6
		159	9
		163	13
3.	200	184	-16
		208	8
		229	29

Berdasarkan hasil pengujian pada Tabel 5.7, sistem mampu melakukan estimasi berat nasi dengan cukup baik berdasarkan luas

area hasil segmentasi. Pada beberapa sampel, hasil estimasi menunjukkan nilai yang mendekati berat aktual, seperti pada data ke-4 dengan berat aktual 150 gram dan hasil estimasi 156 gram, sehingga selisihnya hanya 6 gram. Namun, terdapat juga beberapa data dengan selisih yang cukup besar, seperti pada data ke-2 dengan selisih 33 gram. Perbedaan hasil estimasi tersebut dapat dipengaruhi oleh bentuk, ketebalan, persebaran nasi, serta jarak pemotretan citra yang memengaruhi luas area segmentasi objek pada gambar. Semakin berbeda jarak pengambilan gambar, maka ukuran objek yang terdeteksi pada citra juga dapat berubah sehingga memengaruhi hasil estimasi berat. Secara keseluruhan, sistem berhasil memberikan estimasi berat yang cukup mendekati berat aktual.

5.2.4. Pengujian Layanan REST API

Pengujian layanan REST API dilakukan untuk memastikan sistem mampu menerima citra yang dikirim pengguna, melakukan proses deteksi dan segmentasi menggunakan model YOLO26, serta mengembalikan hasil prediksi dalam format JSON. Hasil pengujian REST API disajikan pada Tabel 5.8.


Tabel 5.6. Hasil Pengujian REST API

No.	Skenario Pengujian	Hasil
1.	Pengiriman citra ke server	Berhasil
2.	Mendeteksi objek makanan	Berhasil
3.	Segmentasi objek nasi	Berhasil
4.	Estimasi berat nasi	Berhasil
5.	Pengembalian data JSON	Berhasil

Berdasarkan Tabel 5.8, seluruh fungsi layanan REST API berhasil dijalankan sesuai dengan kebutuhan sistem. Sistem mampu menerima citra dari pengguna, melakukan proses deteksi dan segmentasi objek makanan, menghitung estimasi berat nasi, serta mengembalikan hasil prediksi dalam format JSON yang dapat digunakan oleh aplikasi klien. Hasil pengujian menunjukkan bahwa integrasi antara model YOLO26 Segmentasi dan layanan REST API telah berjalan dengan baik serta dapat digunakan untuk mendukung implementasi sistem deteksi makanan secara otomatis.

5.2.5. Pengujian Integrasi model

Pengujian integrasi model dilakukan untuk memastikan bahwa model YOLO26 Segmentasi yang telah dilatih dapat diintegrasikan dengan baik ke dalam aplikasi Android dan mampu bekerja sesuai dengan kebutuhan sistem. Pengujian mencakup proses pengambilan gambar menu makanan, pengiriman citra ke server melalui REST API, proses deteksi dan segmentasi objek makanan, estimasi berat nasi, perhitungan kalori, serta penampilan hasil prediksi pada aplikasi. Hasil pengujian integrasi model ditunjukkan pada Gambar 5.8.



Gambar 5.13. Hasil Pengujian Integrasi Model

Berdasarkan Gambar 5.8, aplikasi berhasil menampilkan hasil deteksi dan analisis menu makanan yang terdiri dari komponen karbohidrat, protein, buah, dan sayur. Sistem juga mampu melakukan estimasi berat nasi sebesar 20 gram dengan estimasi kalori sebesar 25 *kkal* berdasarkan hasil segmentasi objek nasi.

Hasil pengujian menunjukkan bahwa seluruh proses integrasi mulai dari pengambilan citra pada aplikasi Android, pengiriman data ke server, pemrosesan menggunakan model YOLO26 Segmentasi, hingga penampilan hasil prediksi pada antarmuka pengguna telah berjalan dengan baik. Informasi hasil deteksi, estimasi berat nasi, estimasi kalori, serta status kelengkapan menu dapat ditampilkan secara otomatis dan mudah dipahami oleh pengguna. Dengan demikian, integrasi model ke dalam aplikasi berhasil diimplementasikan.

BAB VI

KESIMPULAN DAN SARAN

6.1. Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan mengenai implementasi model YOLO26 Segmentasi untuk deteksi makanan dan estimasi berat nasi pada menu Makan Bergizi Gratis (MBG), maka dapat diambil beberapa kesimpulan sebagai berikut:

1. Model YOLO26 Segmentasi berhasil diimplementasikan untuk mendeteksi dan melakukan segmentasi enam kelas objek makanan, yaitu nasi, protein, sayur, buah, karbohidrat, dan susu pada citra menu Makan Bergizi Gratis (MBG).
2. Hasil pengujian menunjukkan bahwa model memiliki kemampuan yang baik dalam mendeteksi dan melakukan segmentasi objek makanan pada berbagai jumlah data pengujian. Pada pengujian menggunakan 50 citra, model memperoleh nilai mAP50 segmentasi sebesar 88,6%, sedangkan pada pengujian menggunakan 115 citra dan 690 citra masing-masing memperoleh nilai mAP50 segmentasi sebesar 78,3% dan 77,5%. Hasil tersebut menunjukkan bahwa model tetap mampu mempertahankan performa yang baik meskipun jumlah dan variasi data pengujian meningkat.
3. Berdasarkan hasil evaluasi segmentasi kelas nasi sebagai fokus utama penelitian, model menunjukkan performa yang sangat baik pada seluruh skenario pengujian. Nilai mAP50 yang diperoleh masing-masing sebesar

96,3% pada pengujian 50 citra, 98,3% pada pengujian 115 citra, dan 98,6% pada pengujian 690 citra. Hasil tersebut menunjukkan bahwa model mampu melakukan segmentasi objek nasi secara akurat dan konsisten pada berbagai kondisi.

4. Sistem berhasil melakukan estimasi berat nasi berdasarkan luas area hasil segmentasi. Hasil pengujian menunjukkan bahwa estimasi berat yang dihasilkan memiliki kedekatan dengan berat aktual sehingga metode segmentasi yang digunakan dapat dimanfaatkan sebagai dasar dalam proses estimasi berat nasi pada menu MBG.
5. Layanan REST API yang dibangun menggunakan Flask berhasil menghubungkan model YOLO26 Segmentasi dengan aplikasi Android. Sistem mampu menerima citra, melakukan proses deteksi dan segmentasi, menghitung estimasi berat nasi, serta mengembalikan hasil prediksi dalam format JSON dengan baik.
6. Integrasi model ke dalam aplikasi Android berhasil dilakukan. Aplikasi mampu menampilkan hasil deteksi makanan, estimasi berat nasi, estimasi kalori, serta status kelengkapan menu secara otomatis sehingga dapat digunakan sebagai alat bantu dalam proses pemantauan dan evaluasi menu Makan Bergizi Gratis (MBG).

6.2. Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat digunakan untuk pengembangan penelitian selanjutnya, yaitu:

1. Menambah jumlah *dataset* dan variasi objek makanan agar model dapat mempelajari lebih banyak karakteristik makanan sehingga performa deteksi dan segmentasi dapat ditingkatkan.
2. Menyeimbangkan jumlah data anotasi pada setiap kelas, khususnya kelas karbohidrat dan susu yang memiliki jumlah data lebih sedikit dibandingkan kelas lainnya, sehingga model dapat menghasilkan performa yang lebih merata pada seluruh kelas.
3. Melakukan pengembangan model lebih lanjut untuk meningkatkan akurasi deteksi, segmentasi, dan estimasi berat makanan yang dihasilkan sistem.
4. Mengembangkan metode estimasi berat nasi dengan mempertimbangkan faktor jarak pengambilan gambar, sudut kamera, dan kondisi pencahayaan agar hasil estimasi berat menjadi lebih akurat.
5. Mengembangkan sistem agar tidak hanya mampu mengestimasi berat nasi, tetapi juga berat dan kandungan gizi komponen makanan lainnya seperti protein, sayur, buah, karbohidrat, dan susu.
6. Melakukan implementasi model secara langsung pada perangkat *mobile* (*on-device inference*) sehingga proses deteksi dapat dilakukan tanpa bergantung pada koneksi internet dan server eksternal.

DAFTAR PUSTAKA

- [1] L. Hermawati, N. B. U. Irawati, H. A. Zulfa, and W. A. Diana, "The Role of Balanced Nutrition Knowledge in Influencing Nutritional Status and Health Risks: A Literature Review," *Int. J. Occup. Med. Public Heal.*, pp. 1–14, 2022.
- [2] I. Mardalena, *Dasar-dasar Ilmu Gizi dalam Keperawatan: Konsep dan Penerapan pada Asuhan Keperawatan*. Yogyakarta: Pustaka Baru Press, 2021.
- [3] N. W. P. S. S. H. F. Y. N. P. H. A. A. W. D. R. A. A. A. Z. Sibuea, "Analisis Tingkat Pengetahuan Tentang Gizi Seimbang Bagi Remaja di MTS Ex PGA Proyek UNIVA Medan," *Pubhealth J. Kesehat. Masy.*, vol. 1, no. 1, pp. 57–62, 2022.
- [4] A. Wigati, F. Y. K. Sari, and T. Suwanto, "Pentingnya Edukasi Gizi Seimbang untuk Pencegahan Stunting pada Balita," *J. Abdimas Indones.*, vol. 4, no. 2, pp. 155–162, 2022.
- [5] M. A. Bahar, G. F. Galistiani, U. Eliyanti, and A. R. Mohi, "Gambaran Nilai Utilitas Kesehatan Anak dengan Malnutrisi : Studi pada Kasus Stunting, Wasting, dan Underweight di Indonesia," *J. Mandala Pharmacon Indones.*, vol. 10, no. 2, pp. 610–617, Dec. 2024, doi: 10.35311/jmpi.v10i2.656.
- [6] E. D. A. Syifa and R. Djuwita, "Factors Associated with Overweight/Obesity in Adolescent High School Students in Pekanbaru City," *J. Kesehat. Komunitas*, vol. 9, no. 2, pp. 368–378, Aug. 2023, doi: 10.25311/keskom.Vol9.Iss2.1579.
- [7] A. M. Argina, "Penerapan Metode Klasifikasi K-Nearest Neighbor pada Dataset Penderita Penyakit Diabetes," *Indones. J. Data Sci.*, vol. 1, no. 2, pp. 29–33, Jul. 2020, doi: 10.33096/ijodas.v1i2.11.
- [8] M. Mardiana and Y. Yulianto, "The effect of nutrition education on balanced-nutrition knowledge and macronutrient intake among adolescent," *Int. J. Public Heal. Sci.*, vol. 11, no. 2, p. 545, Jun. 2022, doi: 10.11591/ijphs.v11i2.20988.
- [9] A. Kekalih, D. N. Chandra, L. T. Mirtha, I. Khouw, G. Wong, and R. Sekartini, "Dietary intakes, nutritional and biochemical status of 6 months to 12-year-old children before the COVID-19 pandemic era: the South East Asian Nutrition Survey II Indonesia (SEANUTS II) study in Java and Sumatera Islands, Indonesia," *Public Health Nutr.*, vol. 28, no. 1, p. e1, Jan. 2025, doi: 10.1017/S1368980024001654.
- [10] S. A. D. Paat, M. D. Amisi, and A. Asrifuddin, "Gambaran Pengetahuan Gizi Mahasiswa Semester Dua Fakultas Kesehatan Masyarakat Universitas Sam Ratulangi Saat Pembatasan Sosial Masa Pandemi COVID-19," *J. KESMAS*, vol. 10, no. 1, pp. 176–179, 2021.
- [11] P. S. N. S. J. P. P. R. Andhita, "Health Communication Planning Implementation for the Healthy Living Community Movement Program based on Management by Objectives Theory in Banyumas Regency," *Int.*

- Conf. Commun. Sci.*, no. Iccs, pp. 7–15, 2023.
- [12] S. Y. Tan *et al.*, “South East Asian Nutrition Surveys (SEANUTS) II – a multi-country evaluation of nutrition and lifestyle indicators in children aged 12 years and below: rationale and design,” *Public Health Nutr.*, vol. 27, no. 1, p. e150, Apr. 2024, doi: 10.1017/S1368980024000910.
 - [13] S. Patimah, S. Sundari, H. H. Idrus, and R. Noviasy, “Effect of School-Integrated Interventions on Improvement of Nutrition-Health Knowledge and Nutritional Status among Adolescent Girls: A Quasi-Experimental Study,” *Curr. Res. Nutr. Food Sci. J.*, vol. 11, no. 2, pp. 880–893, Aug. 2023, doi: 10.12944/CRNFSJ.11.2.35.
 - [14] M. A. Zemene *et al.*, “Concurrent stunting and overweight or obesity among under-five children in sub-Saharan Africa: a multilevel analysis,” *Arch. Public Heal.*, vol. 81, no. 1, p. 119, Jun. 2023, doi: 10.1186/s13690-023-01138-8.
 - [15] W. S. Lee *et al.*, “Prevalence of undernutrition and associated factors in young children in Malaysia: A nationwide survey,” *Front. Pediatr.*, vol. 10, Aug. 2022, doi: 10.3389/fped.2022.913850.
 - [16] D. A. Amanda, A. Wulansari, and I. Indrawati, “Hubungan Kebiasaan Konsumsi Fast Food dengan Status Gizi pada Remaja di SMAN 8 Kota Jambi,” *J. Akad. Baiturrahim Jambi*, vol. 14, no. 1, pp. 14–20, Mar. 2025, doi: 10.36565/jab.v14i1.779.
 - [17] O. Sirkka, M. Abrahamse-Berkeveld, and E. M. van der Beek, “Complementary Feeding Practices among Young Children in China, India, and Indonesia: A Narrative Review,” *Curr. Dev. Nutr.*, vol. 6, no. 6, p. nzac092, Jun. 2022, doi: 10.1093/cdn/nzac092.
 - [18] S. M. D. Ginting, J. Februhartanty, and H. Khusun, “Association between consumption of ultra-processed foods and beverages with nutritional status of private senior high school students in Pontianak, West Kalimantan, Indonesia,” *World Nutr. J.*, vol. 7, no. i2, pp. 90–103, Feb. 2024, doi: 10.25220/WNJ.V07.i2.0011.
 - [19] H. Andriani, E. Friska, M. Arsyi, A. E. Sutrisno, A. Waits, and N. D. Rahmawati, “A multilevel analysis of the triple burden of malnutrition in Indonesia: trends and determinants from repeated cross-sectional surveys,” *BMC Public Health*, vol. 23, no. 1, p. 1836, Sep. 2023, doi: 10.1186/s12889-023-16728-y.
 - [20] E. Putri Anggraeni, C. E. Putriyanti, and Jaelan, “Tinjauan Literatur: Evaluasi Pelaksanaan Program GERMAS Nasional,” *J. Kesehat.*, vol. 13, no. 2, pp. 168–177, 2024.
 - [21] Ayinun, I. Malik, and Haerana, “Implementasi Program Gerakan Masyarakat Hidup Sehat di Kecamatan Masalle Kabupaten Enrekang,” *J. Ilmu Manaj. dan Adm. Publik*, vol. 4, no. 1, pp. 82–95, 2023, doi: <https://doi.org/10.26618/kimap.v4i1.10499>.
 - [22] R. F. Wulandari, A. Rizqi, and M. I. P. Negara, “Hubungan Pengetahuan Gizi Seimbang dengan Status Gizi Sebagai Indikator Keberhasilan Program Makan Bergizi Gratis Pada Siswa,” *Abdimas Awang Long*, vol. 8, no. 2, pp. 283–290, Jun. 2025, doi: 10.56301/awal.v8i2.1683.

- [23] U. Agustini, “Efektivitas dan Tantangan Kebijakan Program Makan Bergizi Gratis sebagai Intervensi Pendidikan di Indonesia,” *J. Kiprah Pendidik.*, vol. 4, no. 3, pp. 362–368, Jul. 2025, doi: 10.33578/kpd.v4i3.p362-368.
- [24] D. T. Ayuni, “Dilema Pelaksanaan Program Makan Bergizi Gratis Pada Siswa,” *J. Multidisiplin Ilmu Sos.*, vol. 8, no. 8, pp. 1–9, 2025.
- [25] A. T. Hasibuan, T. Dalimunte, and Sahlan, “Dari Piring Ke Prestasi : Dampak Makanan Bergizi Gratis Di Sekolah Dasar,” *J. Pendidik. Dasar*, vol. 16, no. 2, pp. 311–325, 2025, doi: 10.21009/JPD.XXX.
- [26] N. Herniati and Idawati, “Efektivitas Program Pemerintah MBG (Makan Bergizi Gratis) Terhadap Minat Belajar Anak Usia Dini,” *J. Pendidik. AURA*, vol. 6, no. 1, pp. 88–98, 2025, doi: 10.37216/aura.v6i1.2484.
- [27] R. Qomarrullah, S. Suratni, L. Wulandari S, and M. Sawir, “Dampak Jangka Panjang Program Makan Bergizi Gratis terhadap Kesehatan dan Keberlanjutan Pendidikan,” *Indones. J. Intellect. Publ.*, vol. 5, no. 2, pp. 130–137, Mar. 2025, doi: 10.51577/ijipublication.v5i2.660.
- [28] Q. Zhang *et al.*, “Eliminate the hardware: Mobile terminals-oriented food recognition and weight estimation system,” *Front. Nutr.*, vol. 9, pp. 1–12, Nov. 2022, doi: 10.3389/fnut.2022.965801.
- [29] N. Purwati, R. R. Isnanto, and M. I. Kartasurya, “Computer Vision for Food Nutrition Assessment: A Bibliometric Analysis and Technical Review,” *J. Robot. Control*, vol. 6, no. 5, pp. 2141–2151, 2025, doi: 10.18196/jrc.v6i5.27525.
- [30] W. Zhang, Q. Yu, B. Siddiquie, A. Divakaran, and H. Sawhney, ““Snap-n-Eat,”” *J. Diabetes Sci. Technol.*, vol. 9, no. 3, pp. 525–533, May 2015, doi: 10.1177/1932296815582222.
- [31] L. M. Amugongo, A. Kriebitz, A. Boch, and C. Lütge, “Mobile Computer Vision-Based Applications for Food Recognition and Volume and Calorific Estimation: A Systematic Review,” *Healthc.*, vol. 11, no. 1, 2023, doi: 10.3390/healthcare11010059.
- [32] E. Shonkoff *et al.*, “AI-based digital image dietary assessment methods compared to humans and ground truth: a systematic review,” *Ann. Med.*, vol. 55, no. 2, p., 2023, doi: 10.1080/07853890.2023.2273497.
- [33] K. V. Dalakleidi, M. Papadelli, I. Kapolos, and K. Papadimitriou, “Applying Image-Based Food-Recognition Systems on Dietary Assessment: A Systematic Review,” *Adv. Nutr.*, vol. 13, no. 6, pp. 2590–2619, Nov. 2022, doi: 10.1093/advances/nmac078.
- [34] A. Gelli *et al.*, “Computer vision-assisted dietary assessment through mobile phones in female youth in urban Ghana: validity against weighed records and comparison with 24-h recalls,” *Am. J. Clin. Nutr.*, vol. 120, no. 5, pp. 1105–1113, 2024, doi: 10.1016/j.ajcnut.2024.08.011.
- [35] J. Redmon and A. Farhadi, “YOLOv3: An Incremental Improvement,” *arXiv Prepr.*, Apr. 2018, [Online]. Available: <http://arxiv.org/abs/1804.02767>
- [36] L. Hoyer, M. Munoz, P. Katiyar, A. Khoreva, and V. Fischer, “Grid Saliency for Context Explanations of Semantic Segmentation,” *arXiv Prepr.*, no. NeurIPS, Nov. 2019, [Online]. Available:

- <https://arxiv.org/abs/1907.13054>
- [37] O. M. Lawal, "YOLOv5-LiNet: A lightweight network for fruits instance segmentation," *PLoS One*, vol. 18, no. 3 March, pp. 1–19, 2023, doi: 10.1371/journal.pone.0282297.
 - [38] Y. Dai, S. Park, and K. Lee, "Utilizing Mask R-CNN for Solid-Volume Food Instance Segmentation and Calorie Estimation," *Appl. Sci.*, vol. 12, no. 21, p. 10938, Oct. 2022, doi: 10.3390/app122110938.
 - [39] N. Karthikeyan, B. Natarajan, S. R. Mahapatro, and D. M. Hussain, "Enhancing dietary management and nutritional analysis through deep learning: a multi-model approach for food classification and volume estimation," *Sci. Rep.*, vol. 16, no. 1, p. 2875, Jan. 2026, doi: 10.1038/s41598-025-32610-w.
 - [40] D. Lee and S. Kwon, "Amount Estimation Method for Food Intake Based on Color and Depth Images through Deep Learning.," *Sensors (Basel)*, vol. 24, no. 7, p. 2044, Mar. 2024, doi: 10.3390/s24072044.
 - [41] R. Supriyadi *et al.*, "PENGEMBANGAN APLIKASI ESTIMASI KALORI MAKANAN BERBASIS CITRA DENGAN PENDEKATAN DETEKSI OBJEK MENGGUNAKAN YOLO," *J. Inform. dan Tek. Elektro Terap.*, vol. 14, no. 1, pp. 1393–1404, Jan. 2026, doi: 10.23960/jitet.v14i1.8545.
 - [42] C.-T. Yeh, T.-M. Chen, and Z.-J. Liu, "Flexible IoT Cloud Application for Ornamental Fish Recognition Using YOLOv3 Model," *Sensors Mater.*, vol. 34, no. 3, p. 1229, Mar. 2022, doi: 10.18494/SAM3574.
 - [43] K. Ponto, L. Hartung, Y. Zhao, B. Sprecher, R. Tredinnick, and S. Banerjee, "EasyVizAR: Supporting First Responders Through the Use of Collaborative Augmented Reality Tools," *Appl. Sci.*, vol. 15, no. 21, p. 11498, Oct. 2025, doi: 10.3390/app152111498.
 - [44] K. V. Dalakleidi, M. Papadelli, I. Kaposos, and K. Papadimitriou, "Applying Image-Based Food-Recognition Systems on Dietary Assessment: A Systematic Review," *Adv. Nutr.*, vol. 13, no. 6, pp. 2590–2619, Nov. 2022, doi: 10.1093/advances/nmac078.
 - [45] R. Agarwal, T. Choudhury, N. J. Ahuja, and T. Sarkar, "Hybrid Deep Learning Algorithm-Based Food Recognition and Calorie Estimation," *J. Food Process. Preserv.*, vol. 2023, pp. 1–15, Nov. 2023, doi: 10.1155/2023/6612302.
 - [46] J. Ferreira, P. Cerqueira, and J. Ribeiro, "Food Waste Detection in Canteen Plates Using YOLOv11," *Appl. Sci.*, vol. 15, no. 13, p. 7137, Jun. 2025, doi: 10.3390/app15137137.
 - [47] G. Chrintz-Gath, M. Daivadanam, L. Matta, and S. McKeever, "Image-Based Dietary Assessment Using the Swedish Plate Model: Evaluation of Deep Learning–Based You Only Look Once (YOLO) Models," *JMIR Form. Res.*, vol. 9, pp. e70124–e70124, Aug. 2025, doi: 10.2196/70124.
 - [48] B. Gonzalez, G. Garcia, S. A. Velastin, H. GholamHosseini, L. Tejeda, and G. Farias, "Automated Food Weight and Content Estimation Using Computer Vision and AI Algorithms," *Sensors*, vol. 24, no. 23, p. 7660, Nov. 2024, doi: 10.3390/s24237660.
 - [49] R. K. S. and J. P. Kumar, "Food Object Detection Using Custom-Trained

- YOLOv8 with Roboflow Integration,” *Eng. Technol. Appl. Sci. Res.*, vol. 15, no. 6, pp. 30508–30513, Dec. 2025, doi: 10.48084/etasr.14810.
- [50] I. D. Mienye and T. G. Swart, “A Comprehensive Review of Deep Learning: Architectures, Recent Advances, and Applications,” *Information*, vol. 15, no. 12, p. 755, Nov. 2024, doi: 10.3390/info15120755.
 - [51] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, May 2015, doi: 10.1038/nature14539.
 - [52] C. Tian *et al.*, “A survey on deep learning fundamentals,” *Artif. Intell. Rev.*, vol. 58, no. 12, p. 381, Oct. 2025, doi: 10.1007/s10462-025-11368-7.
 - [53] M. Fachrisyam, D. Indra, and M. Hasnawi, “Implementasi Metode YOLO Dalam Mendeteksi Jenis Sampah Berbasis Computer Vision,” *LINIER Lit. Inform. dan Komput.*, vol. 2, no. 1, pp. 68–76, Apr. 2025, doi: 10.33096/linier.v2i1.2788.
 - [54] T. A. D. S. R. U. . S. M. E. . Najoan, “Computer Vision Implementation for Detection and Counting the Number of Humans,” *J. Tek. Inform.*, vol. 16, no. 1, pp. 65–76, 2021, [Online]. Available: <https://ejournal.unsrat.ac.id/index.php/informatika>
 - [55] A. Zizwan Putra, M. Harahap, A. Husein, and A. Simarmata, “Klasifikasi Buah Guava Menggunakan Computer Vision,” *Data Sci. Indones.*, vol. 3, no. 2, pp. 102–107, Jun. 2024, doi: 10.47709/dsi.v3i2.4006.
 - [56] R. A. Z. A. Syefudin, “Tinjauan Pustaka Sistematis: Penerapan Metode Position Averaging Point Pada Computer Vision,” *J. Autom. Comput. Inf. Syst.*, vol. 2, no. 02, pp. 108–115, 2022.
 - [57] A. Wang, H. Wu, and Y. Iwahori, “Advances in Computer Vision and Deep Learning and Its Applications,” *Electronics*, vol. 14, no. 8, p. 1551, Apr. 2025, doi: 10.3390/electronics14081551.
 - [58] A. Fadjeri, L. Kurniatin, D. K. Adri Ariyanto, and B. A. Saputra, “Analisis Perbandingan Hasil Pengolahan Citra Asli Dan Cropping Untuk Mengidentifikasi Karakteristik Tanaman Selada Menggunakan Metode Morfologi Dan Ekstraksi Ciri,” *J. Ilm. SINUS*, vol. 21, no. 1, p. 73, Jan. 2023, doi: 10.30646/sinus.v21i1.664.
 - [59] J. Jumadi, Yupianti, and D. Sartika, “Pengolahan Citra Digital untuk Identifikasi Objek Menggunakan Metode Hierarchical Agglomerative Clustering,” *J. Sains dan Teknol.*, vol. 10, no. 2, pp. 148–156, 2021.
 - [60] Y. A. R. H. Syahputra, “Pengenalan Teknologi Pengolahan Citra Digital (Digital Image Processing) untuk Santri di Rahmatan Lil’alamin International Islamic Boarding School,” *Community Dev. J.*, vol. 3, no. 2, pp. 1239–1244, 2022.
 - [61] F. D. Adhinata, A. C. Wardhana, D. P. Rakhmadani, and A. Jayadi, “Peningkatan Kualitas Citra pada Citra Digital Gelap,” *J. E-Komtek*, vol. 4, no. 2, pp. 136–144, Dec. 2020, doi: 10.37339/e-komtek.v4i2.373.
 - [62] H. Y. A. Swasono, A. R. Himamunanto, and F. Maedjaja, “Implementasi YOLO11 dan OpenCV untuk Pengenalan Frasa dalam Video Real-Time Bahasa Isyarat Tangan,” *MALCOM Indones. J. Mach. Learn. Comput. Sci.*, vol. 5, no. 3, pp. 1061–1073, Jul. 2025, doi: 10.57152/malcom.v5i3.2130.
 - [63] Yudistira Bagus Pratama and Nurzaidah Putri Dalimunthe, “Implementasi

- Teknik Computer Vision Untuk Deteksi Viridiplantae Pada Lahan Pasca Tambang,” *Bull. Comput. Sci. Res.*, vol. 3, no. 1, pp. 64–72, Dec. 2022, doi: 10.47065/bulletincsr.v3i1.193.
- [64] K. K. Pal, S. K. Pal, S. Srivastava, H. S. Shyam, and S. Singh, *Proceedings of the International Conference on Sustainable Business Practices and Innovative Models (ICSBPIM-2025)*, vol. 349. in *Advances in Economics, Business and Management Research*, vol. 349. Dordrecht: Atlantis Press International BV, 2025. doi: 10.2991/978-94-6463-872-1.
- [65] N. M. Surbakti *et al.*, “Penggunaan Bahasa Pemrograman Python dalam Pembelajaran Kalkulus Fungsi Dua Variabel,” *Algoritma. J. Mat. Ilmu Pengetah. Alam, Kebumihan dan Angkasa*, vol. 2, no. 3, pp. 98–107, May 2024, doi: 10.62383/algoritma.v2i3.67.
- [66] F. M. Ardana, M. N. Tiadah, M. A. Adinata, Z. Z. Zulkarnain, A. T. Sabela, and M. A. Fadhlullah, “Analisis Survei Perbandingan Penggunaan Tingkatan Bahasa Pemrograman bagi Mahasiswa Teknik Informatika Universitas Negeri Semarang,” *J. Angka*, vol. 1, no. 1, pp. 69–82, 2024, [Online]. Available: <http://jurnalilmiah.org/journal/index.php/angka>
- [67] S. R. A. S. D. S. H. K. I. G. P. R. P. M. Zen, *PYTHON: Dasar dan Pemrograman Berorientasi Objek*. Tahta Media Group, 2023.
- [68] Haeruddin, Sabariman, and V. Suc, “Designing a Chatbot Application Using the Flask Framework and Rule-Based Algorithm,” *J. Teknol. dan Sist. Inf. Bisnis*, vol. 7, no. 1, pp. 133–142, 2025, doi: 10.47233/jteksis.v5i1.1820.
- [69] N. F. Syafi’i, R. R. Harahap, and C. Rizal, “Pembuatan Aplikasi Berita Menggunakan Flask Python,” *J. Minfo Polgan*, vol. 13, no. 2, pp. 2515–2520, Feb. 2025, doi: 10.33395/jmp.v13i2.14537.
- [70] M. Singh, A. Verma, A. Parasher, N. Chauhan, and G. Budhiraja, “Implementation of Database Using Python Flask Framework,” *Int. J. Eng. Comput. Sci.*, vol. 8, no. 12, pp. 24894–24899, 2019, doi: 10.18535/ijecs/v8i12.4399.
- [71] M. G. L. P. M. I. A. Putera, “Analisis Perbandingan Metode SOAP dan REST yang Digunakan pada Framework Flask untuk Membangun Web Service,” *SCAN*, vol. 14, no. 2, pp. 1–7, 2019.
- [72] Febby Wilyani, Qonaah Nuryan Arif, and Fitri Aslimar, “Pengenalan Dasar Pemrograman Python Dengan Google Colaboratory,” *J. Pelayanan dan Pengabd. Masy. Indones.*, vol. 3, no. 1, pp. 08–14, Mar. 2024, doi: 10.55606/jppmi.v3i1.1087.
- [73] Y. Sytnykova, V. Kyrpenko, S. Palevych, O. Pochuieva, S. Lamtiuhova, and O. Chaika, “Implementation of Professionally Oriented Tasks with Interactive Cloud Environment Google Colab,” *Int. J. Interact. Mob. Technol.*, vol. 19, no. 9, pp. 73–91, 2025, doi: 10.3991/ijim.v19i09.53459.
- [74] T. Carneiro, R. V. Medeiros Da Nobrega, T. Nepomuceno, G.-B. Bian, V. H. C. De Albuquerque, and P. P. R. Filho, “Performance Analysis of Google Colaboratory as a Tool for Accelerating Deep Learning Applications,” *IEEE Access*, vol. 6, pp. 61677–61685, 2018, doi: 10.1109/ACCESS.2018.2874767.

- [75] S. Octarina, F. M. Puspita, E. Yuliza, and I. Indrawati, "PENDAMPINGAN PENGGUNAAN GOOGLE COLAB PADA PEMBELAJARAN PYTHON DAN MACHINE LEARNING BAGI DOSEN MATEMATIKA DI PALEMBANG," *J. Pepadu*, vol. 6, no. 1, pp. 56–66, Mar. 2025, doi: 10.29303/pepadu.v6i1.6457.
- [76] M. A. F. H. D. F. Alamsyah, "Analisis Pola Asosiasi Penjualan Produk Ritel dengan Platform Google Colab," *JUSTIFY J. Sist. Inf. Ibrahimy*, vol. 3, no. 1, pp. 74–85, 2024, doi: 10.35316/justify.v3i1.5565.
- [77] N. J. Hayati, D. Singasatia, and M. R. Muttaqin, "Object Tracking Menggunakan Algoritma You Only Look Once (YOLO)v8 untuk Menghitung Kendaraan," *KOMPUTA J. Ilm. Komput. dan Inform.*, vol. 12, no. 2, pp. 91–99, 2023.
- [78] N. Sary, H. H. S. Pasaribu, R. J. Situmeang, and R. D. Darus, "Implementasi Algoritma YOLOv11 dan Roboflow untuk Deteksi Tingkat Kematangan Anggur Berbasis Web," *METIK J.*, vol. 9, no. 2, pp. 264–274, 2025, doi: 10.47002/metik.v9i2.1121.
- [79] R. S. Saputri, A. Apriliani, R. S. Amar, and L. Y. Astri, "Deteksi Dini Microsleep Pada Pengemudi Kendaraan Roda Empat Melalui Citra Mata Menggunakan Algoritma YOLOv8," *J. Process.*, vol. 20, no. 2, pp. 165–179, Oct. 2025, doi: 10.33998/processor.2025.20.2.2529.
- [80] P. Robicheaux *et al.*, "Roboflow100-VL: A Multi-Domain Object Detection Benchmark for Vision-Language Models," *arXiv Prepr.*, no. NeurIPS, pp. 1–32, Oct. 2025, doi: 10.48550/arXiv.2505.20612.
- [81] M. Andrzejewska and A. Stolinska, "Do Structured Flowcharts Outperform Pseudocode? Evidence From Eye Movements," *IEEE Access*, vol. 10, no. December, pp. 132965–132975, 2022, doi: 10.1109/ACCESS.2022.3230981.
- [82] J. Li, "Using Flowchart to Help Students Learn Basic Circuit Theories Quickly," *Sustainability*, vol. 14, no. 12, p. 7516, Jun. 2022, doi: 10.3390/su14127516.
- [83] P. Zhang, W. Dou, and H. Liu, "Hierarchical data structures for flowchart," *Sci. Rep.*, vol. 13, no. 1, p. 5800, Apr. 2023, doi: 10.1038/s41598-023-31968-z.
- [84] F. A. Tohari, R. Primananda, and N. H. Shaffan, "Pengembangan Pembagian Beban Kerja Server Cluster Docker Swarm Berbasis Raspberry Dengan Metode Loadbalancer IP HASH Serta Terautomasi Ansible," *J. Teknol. Inf. dan Ilmu Komput.*, vol. 12, no. 3, pp. 497–504, Jun. 2025, doi: 10.25126/jtiik.2025129466.
- [85] A. B. Amjoud and M. Amrouch, "Transfer Learning for Automatic Image Orientation Detection Using Deep Learning and Logistic Regression," *IEEE Access*, vol. 10, pp. 128543–128553, 2022, doi: 10.1109/ACCESS.2022.3225455.
- [86] M. Hashemi, "Enlarging smaller images before inputting into convolutional neural network: zero-padding vs. interpolation," *J. Big Data*, vol. 6, no. 1, p. 98, Dec. 2019, doi: 10.1186/s40537-019-0263-7.
- [87] T. Zhu, A. Li, Y.-G. Wang, W. Su, and D. Jiang, "DMET: Dynamic Mask-

Enhanced Transformer for Generalizable Deep Image Denoising,”
Mathematics, vol. 13, no. 13, p. 2167, Jul. 2025, doi:
10.3390/math13132167.

LAMPIRAN